

**IMPLEMENTASI HYBRID CONTENT-BASED FILTERING PADA
SISTEM REKOMENDASI SKINCARE MENGGUNAKAN
RESNET-50 DAN TF-IDF**

SKRIPSI

Diajukan untuk memenuhi salah satu syarat mencapai derajat Sarjana
Program Studi Sistem Informasi



disusun oleh

RIZALDI YANUAR

22.12.2453

Kepada


**FAKULTAS ILMU KOMPUTER
UNIVERSITAS AMIKOM YOGYAKARTA
YOGYAKARTA**

2026

**IMPLEMENTASI HYBRID CONTENT-BASED FILTERING PADA
SISTEM REKOMENDASI SKINCARE MENGGUNAKAN
RESNET-50 DAN TF-IDF**

SKRIPSI

untuk memenuhi salah satu syarat mencapai derajat Sarjana
Program Studi Sistem Informasi



disusun oleh

RIZALDI YANUAR

22.12.2453

Kepada

**FAKULTAS ILMU KOMPUTER
UNIVERSITAS AMIKOM YOGYAKARTA
YOGYAKARTA
2026**

HALAMAN PERSETUJUAN

SKRIPSI

**IMPLEMENTASI HYBRID CONTENT-BASED FILTERING PADA
SISTEM REKOMENDASI SKINCARE MENGGUNAKAN
RESNET-50 DAN TF-IDF**

yang disusun dan diajukan oleh

Rizaldi Yanuar

22.12.2453

telah disetujui oleh Dosen Pembimbing Skripsi
pada tanggal 19 Mei 2026

Dosen Pembimbing,



M. Nuraminudin, S.Kom., M.Kom.

NIK. 190302408

HALAMAN PENGESAHAN
SKRIPSI
IMPLEMENTASI HYBRID CONTENT-BASED FILTERING PADA
SISTEM REKOMENDASI SKINCARE MENGGUNAKAN
RESNET-50 DAN TF-IDF

yang disusun dan diajukan oleh

Rizaldi Yanuar

22.12.2453

Telah dipertahankan di depan Dewan Penguji
pada tanggal 19 Mei 2026

Susunan Dewan Penguji

Nama Penguji

Tanda Tangan

Yoga Pristyanto, S.Kom., M.Eng.
NIK. 190302412



Atik Nurmasani, S.Kom., M.Kom.
NIK. 190302354



M. Nuraminudin, S.Kom., M.Kom.
NIK. 190302408



Skripsi ini telah diterima sebagai salah satu persyaratan
untuk memperoleh gelar Sarjana Komputer
Tanggal 19 Mei 2026

DEKAN FAKULTAS ILMU KOMPUTER



Prof. Dr. Kusriani, S.Kom., M.Kom.
NIK. 190302106

HALAMAN PERNYATAAN KEASLIAN SKRIPSI

Yang bertandatangan di bawah ini,

Nama mahasiswa : Rizaldi Yanuar
NIM : 22.12.2453

Menyatakan bahwa Skripsi dengan judul berikut:

**IMPLEMENTASI HYBRID CONTENT-BASED FILTERING PADA
SISTEM REKOMENDASISKINCARE MENGGUNAKAN
RESNET-50 DAN TF-IDF**

Dosen Pembimbing : M. Nuraminudin, S.Kom., M.Kom.

1. Karya tulis ini adalah benar-benar ASLI dan BELUM PERNAH diajukan untuk mendapatkan gelar akademik, baik di Universitas AMIKOM Yogyakarta maupun di Perguruan Tinggi lainnya.
2. Karya tulis ini merupakan gagasan, rumusan dan penelitian SAYA sendiri, tanpa bantuan pihak lain kecuali arahan dari Dosen Pembimbing.
3. Dalam karya tulis ini tidak terdapat karya atau pendapat orang lain, kecuali secara tertulis dengan jelas dicantumkan sebagai acuan dalam naskah dengan disebutkan nama pengarang dan disebutkan dalam Daftar Pustaka pada karya tulis ini.
4. Perangkat lunak yang digunakan dalam penelitian ini sepenuhnya menjadi tanggung jawab SAYA, bukan tanggung jawab Universitas AMIKOM Yogyakarta.
5. Pernyataan ini SAYA buat dengan sesungguhnya, apabila di kemudian hari terdapat penyimpangan dan ketidakbenaran dalam pernyataan ini, maka SAYA bersedia menerima SANKSI AKADEMIK dengan pencabutan gelar yang sudah diperoleh, serta sanksi lainnya sesuai dengan norma yang berlaku di Perguruan Tinggi.

Yogyakarta, 19 Mei 2026

Yang Menyatakan,


Rizaldi Yanuar

KATA PENGANTAR

Puji syukur penulis panjatkan kehadiran Tuhan Yang Maha Esa, yang telah melimpahkan rahmat, hidayah, serta karunia-Nya, sehingga penulis dapat menyelesaikan laporan tugas akhir ini dengan lancar. Tugas akhir ini disusun untuk memenuhi salah satu syarat kelulusan Program Sarjana pada Fakultas Ilmu Komputer Universitas Amikom Yogyakarta.

Selain itu penulis dengan segala kerendahan hati ingin menyampaikan rasa terima kasih kepada semua pihak yang telah berjasa memberikan dukungan dan bantuan untuk menyelesaikan laporan tugas akhir ini. Untuk itu penulis mengucapkan terima kasih kepada:

1. Bapak Prof. Dr. M. Suyanto, M.M., selaku Rektor Universitas Amikom Yogyakarta
2. Ibu Prof. Dr. Kusrini, S.Kom., M.Kom., selaku Dekan Program Fakultas Ilmu Komputer Universitas AMIKOM Yogyakarta
3. Bapak Anggit Dwi Hartanto, M.Kom., selaku Ketua Program Studi Sistem Informasi Universitas AMIKOM Yogyakarta
4. Bapak M. Nuraminudin, S.Kom., M.Kom., selaku dosen pembimbing yang memberikan arahan, saran, dan motivasi terhadap penulis
5. Kedua orang tua, keluarga besar, dan teman-teman tercinta yang memberikan semangat dan doa kepada penulis.

Yogyakarta, 19 Mei 2026

Rizaldi Yanuar

DAFTAR ISI

HALAMAN JUDUL	i
HALAMAN PERSETUJUAN.....	ii
HALAMAN PENGESAHAN	iii
HALAMAN PERNYATAAN KEASLIAN SKRIPSI	iv
KATA PENGANTAR	v
DAFTAR ISI.....	vi
DAFTAR TABEL.....	ix
DAFTAR GAMBAR.....	x
DAFTAR LAMBANG DAN SINGKATAN	xi
DAFTAR ISTILAH	xii
INTISARI	xiv
ABSTRACT.....	xv
BAB I PENDAHULUAN.....	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	2
1.3 Batasan Masalah	3
1.4 Tujuan Penelitian	3
1.5 Manfaat Penelitian	4
1.6 Sistematika Penulisan	5
BAB II TINJAUAN PUSTAKA	7
2.1 Studi Literatur	7
2.2 Dasar Teori.....	12
2.2.1 Sistem Rekomendasi	12
2.2.2 Hybrid Content-Based Filtering.....	13
2.2.3 Text Mining dan Preprocessing	14
2.2.4 TF-IDF	15
2.2.5 Convolutional Neural Network (CNN)	17
2.2.6 ResNet50.....	18
2.2.7 Cosine Similarity	19

2.2.8 Evaluasi Sistem	21
a. Precision@K	21
b. Silhouette Score	22
c. Visualisasi t-SNE	23
BAB III METODE PENELITIAN	25
3.1 Objek Penelitian	25
3.2 Alur Penelitian	32
3.3 Alat dan Bahan	35
3.3.1 Perangkat Keras (Hardware)	35
3.3.2 Perangkat Lunak (Software)	35
3.3.3 Bahan Penelitian	36
BAB IV HASIL DAN PEMBAHASAN	37
4.1 Pengumpulan Data	37
4.2 Preprocessing Data	38
4.2.1 Data Cleaning	38
a. Handling Duplicates	38
b. Handling Missing Values	39
4.2.2 Text Preprocessing	40
a. Case Folding	40
b. Cleansing	41
c. Whitespace Normalization	42
4.2.3 Image Preprocessing	43
4.3 Ekstraksi Fitur	44
4.3.1 ResNet 50	44
4.3.2 TF-IDF	47
4.4 Cosine Similarity	49
4.5 Sistem Rekomendasi	53
4.6 Evaluasi	55
4.6.1 Precision@5	56
4.6.2 Silhouette Score	57
4.6.3 Visualisasi t-SNE	58

4.6.4 Kesimpulan Evaluasi.....	60
4.7 Deployment.....	60
BAB V PENUTUP	65
5.1 Kesimpulan	65
5.2 Saran	66
REFERENSI	67

DAFTAR TABEL

Tabel 2.1 Keaslian Penelitian	9
Tabel 3.1 Sampel Data Objek Penelitian	25
Tabel 4.1 Struktur Atribut Data	37
Tabel 4.2 Hasil Handling Duplicates	39
Tabel 4.3 Hasil Missing Values	39
Tabel 4.4 Hasil Implementasi Tahap Case Folding	40
Tabel 4.5 Hasil Implementasi Tahap Cleansing	41
Tabel 4.6 Hasil Whitespace Normalization	42
Tabel 4.7 Bukti Akuisisi dan Validasi Lokasi Citra Lokal	44
Tabel 4.8 Hasil Implementasi Ekstraksi Fitur Citra menggunakan ResNet50	45
Tabel 4.9 Hasil Ekstraksi Bobot TF-IDF pada 10 Kata Pertama Ingredients	48
Tabel 4.10 Hasil Komputasi Cosine Similarity dan Pembobotan Hybrid	51
Tabel 4.11 Hasil Top-5 Rekomendasi Produk Skincare (Kueri: "Serum")	54
Tabel 4.12 Hasil Pengujian Precision@5	56
Tabel 4.13 Hasil Pengujian Silhouette Score	58

DAFTAR GAMBAR

Gambar 2.1 Content-Based Filtering	13
Gambar 2.2 Convolutional Neural Network (CNN)	18
Gambar 2.3 Contoh Visualisasi t-SNE	24
Gambar 3.1 Alur Penelitian	33
Gambar 4.1 Hasil screenshot Top-5 Rekomendasi Produk Skincare	54
Gambar 4.2 Visualisasi Scatter Plot t-SNE Berdasarkan Fitur Hibrida	59
Gambar 4.3 Tampilan Halaman Utama dan Kolom Pencarian	61
Gambar 4.4 Tampilan Pemilihan Produk Acuan	62
Gambar 4.5 Tampilan Antarmuka Hasil Rekomendasi Produk	63

DAFTAR LAMBANG DAN SINGKATAN

θ	Sudut yang terbentuk antara dua vektor
$W_{t,d}$	Bobot akhir kata pada dokumen
$\text{Sim}(A, B)$	Skor kemiripan (Cosine Similarity)
S_i	Nilai Silhouette Score
$a(i)$	Jarak rata-rata intra-cluster
$b(i)$	Jarak rata-rata inter-cluster
CNN	Convolutional Neural Network
CSV	Comma Separated Values
FC	Fully Connected
GPU	Graphics Processing Unit
HTTP	Hypertext Transfer Protocol
IDE	Integrated Development Environment
IDF	Inverse Document Frequency
PCA	Principal Component Analysis
ReLU	Rectified Linear Unit
ResNet	Residual Network
RNN	Recurrent Neural Network
SOM	Self Organizing Map
TF	Term Frequency
TF-IDF	Term Frequency-Inverse Document Frequency
TPU	Tensor Processing Unit
t-SNE	t-Distributed Stochastic Neighbor Embedding
URL	Uniform Resource Locator

DAFTAR ISTILAH

Case Folding	Langkah awal penyeragaman teks dengan mengubah semua huruf kapital menjadi huruf kecil.
Cleansing	Proses membuang karakter-karakter derau (seperti angka dan simbol) yang tidak informatif dari data teks.
Cold-start	Kendala pada sistem rekomendasi ketika produk baru belum memiliki riwayat interaksi atau penilaian pengguna.
Content-Based Filtering	Metode pemberian rekomendasi berdasarkan kemiripan atribut spesifik dari sebuah item.
Cosine Similarity	Metode untuk menghitung tingkat kemiripan antara dua vektor dengan mengukur nilai kosinus sudut di antara keduanya.
Deep Learning	Cabang algoritma pembelajaran mesin berbasis jaringan saraf tiruan, seperti arsitektur ResNet50.
Deployment	Tahapan akhir implementasi sistem ke dalam bentuk aplikasi berbasis web agar dapat digunakan secara interaktif.
Hybrid Multimodal	Pendekatan sistem yang mengintegrasikan berbagai jenis representasi fitur sekaligus, yaitu visual (citra) dan tekstual (teks).
Ingredients	Daftar teks komposisi zat kimia dan bahan alami yang menjadi penyusun suatu produk perawatan kulit.
Information Overload	Fenomena kelebihan informasi yang membingungkan konsumen akibat terlalu banyaknya variasi produk di pasaran.

Precision@K	Metrik evaluasi untuk mengukur persentase ketepatan atau relevansi kategori dari rekomendasi pada peringkat teratas.
Preprocessing	Tahapan pengolahan data mentah untuk meminimalkan derau (noise) dan menyeragamkan format sebelum diolah algoritma.
ResNet50	Arsitektur Convolutional Neural Network dengan kedalaman 50 lapisan untuk mengekstraksi fitur visual gambar.
Silhouette Score	Metrik evaluasi yang mengukur validitas dan kualitas batas pengelompokan (klaster) data di dalam ruang vektor.
Term Frequency (TF)	Metrik yang mengukur seberapa sering sebuah kata (term) muncul dalam satu dokumen tertentu.
TF-IDF	Metode pembobotan statistik untuk merepresentasikan tingkat kepentingan sebuah kata dalam sebuah dokumen teks.
t-SNE	Algoritma reduksi dimensi untuk memvisualisasikan persebaran data berdimensi tinggi ke dalam grafik dua dimensi.

INTISARI

Perkembangan pesat industri perawatan kulit telah menyebabkan membanjirnya variasi produk di pasaran yang berdampak pada kebingungan konsumen dalam memilih produk yang sesuai preferensinya. Fenomena kelebihan informasi ini menyulitkan pengguna untuk menemukan produk alternatif yang memiliki kemiripan karakteristik, baik dari segi kandungan maupun kemasan, terutama pada produk baru yang belum memiliki riwayat penilaian dari pengguna lain. Penelitian ini bertujuan menyelesaikan masalah tersebut dengan membangun sistem rekomendasi menggunakan pendekatan Hybrid Multimodal Content Based Filtering. Metode ini mengintegrasikan ekstraksi fitur visual dari citra kemasan produk menggunakan algoritma Convolutional Neural Network dengan arsitektur ResNet dan ekstraksi fitur tekstual dari komposisi bahan menggunakan metode pembobotan Term Frequency Inverse Document Frequency. Kedua fitur tersebut digabungkan untuk menghitung tingkat kemiripan antar produk menggunakan algoritma Cosine Similarity. Hasil akhir dari penelitian ini adalah sebuah sistem yang mampu memberikan rekomendasi produk perawatan kulit yang relevan berdasarkan kemiripan visual dan kandungan bahan secara bersamaan. Evaluasi kinerja sistem dilakukan menggunakan metrik presisi kategori dan validasi kluster untuk memastikan kualitas pengelompokan data tanpa label. Penelitian ini memberikan kontribusi nyata bagi konsumen dalam mempermudah pencarian produk yang akurat serta membantu mengatasi kendala rekomendasi pada produk baru yang belum memiliki interaksi pengguna sebelumnya.

Kata kunci: Sistem Rekomendasi, Skincare, Hybrid Multimodal, TF-IDF, ResNet50.

ABSTRACT

The rapid growth of the skincare industry has led to an influx of product variations in the market, resulting in consumer confusion when selecting products that suit their preferences. This phenomenon of information overload complicates the process for users to discover alternative products sharing similar characteristics, both in terms of ingredients and packaging, particularly for new products lacking a history of user ratings. This study aims to address this issue by developing a recommendation system utilizing a Hybrid Multimodal Content-Based Filtering approach. This method integrates visual feature extraction from product packaging images using the Convolutional Neural Network algorithm with ResNet architecture and textual feature extraction from ingredient compositions using the Term Frequency-Inverse Document Frequency weighting method. Both features are combined to calculate the similarity level between products using the Cosine Similarity algorithm. The final outcome of this research is a system capable of providing relevant skincare product recommendations based on visual similarity and ingredient content simultaneously. System performance evaluation is conducted using category precision metrics and cluster validation to ensure the quality of unlabeled data grouping. This study contributes significantly to consumers by facilitating accurate product searches and assisting in overcoming recommendation challenges for new products that lack prior user interaction.

Keyword: Recommendation System, Skincare, Hybrid Multimodal, TF-IDF, ResNet50.

BAB I

PENDAHULUAN

1.1 Latar Belakang

Industri kosmetik di Indonesia saat ini sedang tumbuh sangat pesat dan diprediksi akan terus meningkat nilai pasarnya secara berkelanjutan dari tahun ke tahun [1]. Pertumbuhan tersebut mendorong munculnya berbagai produk skincare dengan fungsi, kandungan bahan, serta klaim manfaat yang semakin beragam. Di sisi lain, perilaku konsumen dalam memilih produk kosmetik juga mengalami perubahan. Konsumen tidak lagi membeli produk hanya berdasarkan popularitas merek, tetapi semakin memperhatikan berbagai informasi yang tersedia sebelum melakukan pembelian. Informasi mengenai kandungan bahan (*ingredients*), manfaat produk, keamanan penggunaan, serta kesesuaian dengan kebutuhan kulit menjadi faktor penting dalam proses pengambilan keputusan [2].

Banyaknya variasi produk yang tersedia menyebabkan konsumen dihadapkan pada jumlah informasi yang sangat besar ketika akan memilih produk skincare. Kondisi ini menimbulkan fenomena *information overload*, yaitu situasi ketika pengguna harus menganalisis terlalu banyak pilihan dan informasi sebelum menentukan produk yang sesuai. Konsumen perlu membandingkan berbagai atribut produk, mulai dari komposisi bahan, fungsi produk, kategori penggunaan, hingga karakteristik visual kemasan. Akibatnya, proses pencarian produk yang sesuai sering kali menjadi lebih sulit dan memerlukan waktu yang lebih lama.

Untuk membantu proses pemilihan produk, berbagai sistem rekomendasi telah dikembangkan. Namun, sistem rekomendasi skincare masih menghadapi tantangan dalam memahami karakteristik produk secara menyeluruh. Sebagian sistem hanya memanfaatkan informasi tekstual, sedangkan sebagian lainnya hanya berfokus pada informasi visual [3]. Padahal, produk skincare memiliki karakteristik multidimensi yang terdiri atas kandungan bahan dan tampilan kemasan yang sama-sama berperan dalam proses identifikasi maupun pencarian produk alternatif. Pemanfaatan satu jenis informasi saja berpotensi menghasilkan rekomendasi yang

kurang mampu merepresentasikan karakteristik produk secara utuh.

Salah satu pendekatan yang dapat digunakan untuk mengatasi keterbatasan tersebut adalah *hybrid multimodal* yang menggabungkan pengolahan data teks dan citra. Pada data teks, metode TF-IDF dapat digunakan untuk memberikan bobot pada kata-kata penting yang terdapat dalam komposisi bahan produk sehingga informasi yang relevan dapat direpresentasikan dengan baik [4]. Pada data citra, arsitektur ResNet-50 mampu mengekstraksi fitur visual yang kompleks dan telah terbukti memiliki kinerja yang baik dalam berbagai tugas pengolahan citra [5]. Kombinasi kedua pendekatan tersebut membuat sistem memperoleh representasi produk yang lebih komprehensif dibandingkan penggunaan satu jenis data saja.

Berdasarkan permasalahan tersebut, penelitian ini mengimplementasikan sistem rekomendasi *hybrid content-based filtering* dengan mengintegrasikan ekstraksi fitur teks menggunakan TF-IDF dan ekstraksi fitur citra menggunakan ResNet-50. Tingkat kemiripan antarproduk dihitung menggunakan *cosine similarity* untuk menghasilkan rekomendasi yang relevan. Sistem yang dikembangkan diharapkan mampu memberikan rekomendasi produk yang memiliki kemiripan baik dari sisi kandungan bahan maupun karakteristik visual sehingga dapat membantu pengguna menemukan alternatif produk yang lebih relevan. Hasil penelitian kemudian direalisasikan dalam bentuk prototype berbasis web sebagai simulasi penyajian rekomendasi produk alternatif bagi pengguna.

1.2 Rumusan Masalah

Berdasarkan uraian latar belakang mengenai fenomena kelebihan informasi (information overload) dalam memilih produk skincare, rumusan masalah pada penelitian ini adalah sebagai berikut:

1. Bagaimana mengimplementasikan metode *Hybrid Content-Based Filtering* yang mengintegrasikan ekstraksi fitur citra menggunakan ResNet50 dan fitur teks menggunakan TF-IDF pada sistem rekomendasi *skincare*?
2. Bagaimana performa dan tingkat akurasi dari hasil rekomendasi produk skincare yang dihasilkan sistem berdasarkan tingkat kemiripan (*similarity*)

dari penggabungan fitur visual kemasan dan komposisi bahan yang dievaluasi menggunakan *Precision@5*, *Silhouette Score*, dan *visualisasi t-SNE*?

1.3 Batasan Masalah

Pembatasan masalah pada penelitian ini ditetapkan sebagai berikut:

1. Data sekunder bersumber dari dataset publik SkinSafe Kaggle. Populasi data dibatasi 4.800 sampel produk. Pengolahan atribut difokuskan pada citra kemasan (*image*), teks komposisi bahan (*ingredients*). Pendekatan sistem murni mengimplementasikan metode *Content-Based Filtering*. Variabel interaksi pengguna berupa rating, review, riwayat pembelian diabaikan.
2. Arsitektur *ResNet50* mengekstraksi fitur citra. Metode pembobotan *TF-IDF* mengekstraksi fitur teks. Algoritma *Cosine Similarity* mengkalkulasi tingkat kemiripan. Rasio pembobotan hibrida bernilai 20% representasi visual, 80% representasi tekstual.
3. Aplikasi web interaktif berbasis framework *Streamlit* menjadi antarmuka sistem. Fungsionalitas sistem menyajikan rekomendasi produk alternatif. Layanan transaksi e-commerce, fitur pembayaran ditiadakan.
4. Tampilan akhir antarmuka menyajikan 5 (Top-5) rekomendasi produk skincare. Urutan rekomendasi tersusun berdasarkan skor kemiripan tertinggi produk acuan pilihan pengguna.
5. Tiga instrumen pengujian mengevaluasi kinerja sistem. Metrik *Precision@5* mengukur akurasi kategori. Komputasi *Silhouette Score* memvalidasi batas klaster data. Algoritma *t-SNE* memetakan sebaran visual data.

1.4 Tujuan Penelitian

Tujuan yang akan dicapai oleh peneliti dalam penelitian ini adalah:

1. Mengimplementasikan metode *Hybrid Content-Based Filtering* pada sistem rekomendasi skincare dengan menggabungkan dua ekstraksi fitur

sekaligus, yaitu fitur visual kemasan menggunakan *ResNet50* dan fitur teks komposisi bahan menggunakan *TF-IDF*, yang diimplementasikan ke dalam antarmuka aplikasi web interaktif berbasis *Streamlit*.

2. Menghasilkan daftar 5 (Top-5) rekomendasi produk skincare yang relevan dengan menghitung skor kemiripan (similarity score) antar produk berdasarkan integrasi data citra dan teks menggunakan rasio pembobotan hibrida (20% citra dan 80% teks) melalui algoritma Cosine Similarity, serta mengevaluasi performa dan tingkat akurasi menggunakan metrik Precision@5, Silhouette Score, dan visualisasi t-SNE.

1.5 Manfaat Penelitian

Penelitian ini diharapkan dapat memberikan kontribusi positif baik dari segi pengembangan ilmu pengetahuan maupun penerapan teknologi di masyarakat. Adapun manfaat yang ingin dicapai dijabarkan sebagai berikut:

1. Manfaat Teoritis
 - a. Menambah literatur akademik di bidang kecerdasan buatan, khususnya mengenai efektivitas integrasi fitur multimodal berbasis deep learning (ResNet-50) dan pembobotan teks (TF-IDF) dalam mengenali karakteristik produk kosmetik.
 - b. Memberikan pemahaman ilmiah yang lebih mendalam mengenai pengaruh penggabungan representasi visual kemasan dan data tekstual bahan aktif terhadap peningkatan relevansi sistem rekomendasi berbasis content-based filtering.
2. Manfaat Praktis
 - a. Menjadi panduan atau referensi bagi pengembang platform e-commerce kosmetik dalam membangun sistem pencarian alternatif produk skincare cerdas yang tidak bergantung pada riwayat interaksi atau data pribadi pengguna.
 - b. Membantu konsumen atau masyarakat luas dalam mengatasi fenomena kelebihan informasi (*information overload*) dengan menyediakan prototype antarmuka web yang mampu menyajikan

referensi produk substitusi secara cepat dan akurat berdasarkan kemiripan fisik maupun kandungan bahan.

- c. Menjadi acuan bagi peneliti selanjutnya untuk mengembangkan sistem rekomendasi lanjutan, khususnya dalam penentuan rasio bobot hibrida optimal serta pemanfaatan kamus stopwords klinis pada domain dermatologi.

1.6 Sistematika Penulisan

Sistematika penulisan skripsi ini disusun untuk memberikan gambaran menyeluruh mengenai alur pembahasan yang terdapat dalam setiap bab. Uraian singkat mengenai isi dari masing-masing bab adalah sebagai berikut:

BAB I PENDAHULUAN, berisi latar belakang masalah mengenai fenomena *information overload* pada produk *skincare*, rumusan masalah, batasan masalah, tujuan penelitian, manfaat penelitian, serta sistematika penulisan laporan. Bab ini menjadi landasan awal mengapa penelitian sistem rekomendasi *hybrid* ini perlu dilakukan.

BAB II TINJAUAN PUSTAKA, berisi tinjauan pustaka dari penelitian-penelitian terdahulu yang relevan, serta landasan teori yang menjadi acuan dalam pengembangan sistem. Teori-teori yang dibahas meliputi konsep Sistem Rekomendasi, *Text Mining*, metode *Term Frequency-Inverse Document Frequency* (TF-IDF), *Deep Learning* dengan *Convolutional Neural Network* (CNN), arsitektur ResNet-50, perhitungan kemiripan *Cosine Similarity*, serta metode evaluasi sistem.

BAB III METODE PENELITIAN, di dalamnya terdapat tinjauan umum tentang objek penelitian, analisis masalah, serta tahapan perancangan sistem yang diusulkan. Bab ini menjabarkan alur kerja penelitian secara sistematis, mulai dari pengumpulan *dataset* sekunder, skenario pengujian, hingga desain arsitektur model *Hybrid Multimodal* yang akan dibangun.

BAB IV HASIL DAN PEMBAHASAN, bab ini merupakan inti dari penelitian yang berisi laporan mengenai proses implementasi metode *Hybrid Multimodal* ke dalam sistem. Di dalamnya dijelaskan secara rinci hasil dari setiap tahapan mulai

dari *preprocessing* data citra dan teks, ekstraksi fitur visual menggunakan arsitektur ResNet-50, pembobotan nilai TF-IDF, hingga perhitungan *Cosine Similarity* untuk menghasilkan rekomendasi. Bab ini juga menyajikan hasil evaluasi performa sistem berdasarkan nilai *Precision@K*, *Silhouette Score*, dan visualisasi *t-SNE*.

BAB V PENUTUP, berisi kesimpulan dari hasil penelitian yang telah dilakukan, serta saran-saran yang konstruktif bagi peneliti selanjutnya untuk pengembangan atau perbaikan sistem rekomendasi di masa mendatang.

BAB II TINJAUAN PUSTAKA

2.1 Studi Literatur

Dalam penyusunan penelitian ini, dilakukan kajian terhadap berbagai literatur terdahulu yang relevan untuk memetakan perkembangan metode sistem rekomendasi dan pengolahan citra pada domain kecantikan. Tinjauan ini mencakup penelitian mengenai metode *Content-Based Filtering* pada produk *skincare*, penggunaan algoritma pembobotan teks, hingga penerapan *Deep Learning* untuk analisis visual.

Penelitian mengenai sistem rekomendasi produk *skincare* telah banyak dilakukan untuk mengatasi masalah kelebihan informasi yang dialami konsumen. Sulami, Atina, dan Nurmalitasari (2024) mengembangkan sistem rekomendasi pemilihan produk *skincare* menggunakan metode *Content-Based Filtering*. Penelitian ini memanfaatkan algoritma TF-IDF (*Term Frequency-Inverse Document Frequency*) dan *cosine similarity* untuk menghitung kemiripan deskripsi produk dari data *e-commerce*. Hasilnya menunjukkan bahwa sistem mampu memberikan rekomendasi yang relevan berdasarkan kueri pengguna tanpa memerlukan data *rating*[6].

Pendekatan serupa juga dilakukan oleh Nouvalina dan Hati (2024), yang membangun sistem rekomendasi produk *skincare* berdasarkan permasalahan kulit wajah. Sistem ini juga menerapkan metode *Content-Based Filtering* dengan TF-IDF dan *Cosine Similarity*, di mana rekomendasi diberikan berdasarkan kecocokan kata kunci masalah kulit [7]. Selain pada produk perawatan kulit, metode berbasis konten juga diterapkan pada produk kosmetik dekoratif. Idris dan Pontoiyo (2025) meneliti sistem rekomendasi untuk produk *makeup*, yang menegaskan bahwa kombinasi TF-IDF dan *Cosine Similarity* efektif dalam menangkap relevansi fitur produk berbasis teks untuk memberikan alternatif produk yang sesuai preferensi pengguna.

Seiring dengan kompleksitas data, pengembangan metode rekomendasi

mulai mengarah pada pendekatan cerdas yang lebih canggih. Dewi dan Ciptayani (2022) melakukan pemodelan sistem rekomendasi cerdas menggunakan pendekatan *Hybrid Deep Learning*. Penelitian ini menggabungkan *Self Organizing Map* (SOM) dan *Recurrent Neural Network* (RNN) untuk menghasilkan model rekomendasi yang optimal, menunjukkan bahwa integrasi metode *Deep Learning* dapat meningkatkan kinerja sistem dibandingkan metode konvensional [8].

Di sisi lain, pemanfaatan *Deep Learning* dalam domain kecantikan juga berkembang pesat pada aspek pengolahan citra digital (*Computer Vision*), khususnya menggunakan arsitektur *Convolutional Neural Network* (CNN). Agustina (2024) menerapkan algoritma CNN dengan arsitektur ResNet-50 untuk klasifikasi citra jenis kulit wajah (normal, kering, berminyak). Penelitian ini membuktikan bahwa ResNet-50 memiliki performa tinggi dalam mengenali fitur visual kulit wajah dengan akurasi mencapai 98,35% [9]. Keandalan arsitektur ResNet-50 juga dikuatkan oleh penelitian Anshori dkk. (2025) yang menggunakannya untuk klasifikasi jenis jerawat secara otomatis. Hasil penelitian menunjukkan bahwa ekstraksi fitur menggunakan ResNet-50 sangat efektif dalam membedakan karakteristik visual yang kompleks pada citra kondisi kulit [10].

Berdasarkan tinjauan literatur di atas, teridentifikasi sebuah celah penelitian (*research gap*). Penelitian rekomendasi *skincare* yang ada, seperti karya Sulami dkk. [6] dan Nouvalina & Hati [7], sebagian besar masih berfokus pada fitur teks (*ingredients*/deskripsi) semata. Sementara itu, keunggulan ResNet-50 dalam mengolah citra produk kecantikan [9], [10] belum banyak dimanfaatkan secara terintegrasi dalam sistem rekomendasi *skincare*. Oleh karena itu, penelitian ini mengusulkan pendekatan *Hybrid Multimodal* yang menggabungkan ekstraksi fitur visual kemasan menggunakan ResNet-50 dan fitur teks komposisi bahan menggunakan TF-IDF. Pendekatan ini diharapkan dapat memberikan rekomendasi yang lebih komprehensif, tidak hanya berdasarkan kandungan bahan, tetapi juga kemiripan visual produk.

Tabel 2.1 Keaslian Penelitian

No	Judul penelitian	Nama Penulis	Tahun Publikasi	Hasil Penelitian	Perbandingan Penelitian
1	Penerapan Metode Content Based Filtering dalam Sistem Rekomendasi Pemilihan Produk Skincare	Sulami, Atina, & Nurmalitasari	2024	Sistem rekomendasi <i>skincare</i> berbasis web menggunakan TF-IDF pada data deskripsi produk Sociolla.	Penelitian terdahulu memproses fitur teks deskripsi produk semata. Penelitian saat ini mengintegrasikan fitur teks komposisi bahan beserta fitur citra kemasan. Rasio pembobotan hibrida menyeimbangkan komputasi. Pengujian metrik Precision@5 mengevaluasi performa akurasi.
2	Sistem Rekomendasi Produk SkinCare Berdasarkan Permasalahan Kulit Wajah dengan Metode Content Based Filtering	Nouvalina & Hati	2024	Sistem memberikan rekomendasi produk berdasarkan input teks keluhan/permasalahan kulit wajah.	Penelitian terdahulu menerima input teks masalah kulit. Penelitian saat ini memproses input nama produk. Sistem mencari referensi alternatif berdasarkan kemiripan visual tekstual. Antarmuka

3	Sistem Rekomendasi Produk Makeup Berbasis Content-Based Filtering dengan TF-IDF dan Cosine Similarity	Idris & Pontooyo	2025	Implementasi TF-IDF dan Cosine Similarity efektif untuk rekomendasi produk <i>makeup</i> .	web Streamlit mendemonstrasikan fungsi pemodelan sistem. Penelitian terdahulu menjadikan kosmetik makeup sasaran pengujian. Penelitian saat ini menjadikan produk skincare objek pengujian via pendekatan multimodal. Pembobotan skor TF-IDF bernilai 80%. Pembobotan skor matriks ResNet50 bernilai 20%.
4	Pemodelan Sistem Rekomendasi Cerdas Menggunakan Hybrid Deep Learning	Dewi & Ciptayani	2022	Model <i>Hybrid</i> (SOM + RNN) menghasilkan akurasi rekomendasi yang lebih baik dibanding metode tunggal.	Penelitian terdahulu mengimplementasikan arsitektur SOM, RNN. Penelitian saat ini mengimplementasikan arsitektur ResNet50 pengekstraksi citra, metode TF-IDF pengekstraksi teks.

					Komputasi Silhouette Score memvalidasi persebaran kluster data. Algoritma t-SNE memvisualisasikan data dimensi.
5	Klasifikasi Citra Jenis Kulit Wajah dengan Algoritma Convolutional Neural Network (CNN) ResNet-50	Agustina	2024	ResNet-50 mampu mengklasifikasikan jenis kulit wajah dengan akurasi sangat tinggi (98,35%).	Penelitian terdahulu berfokus pada proses klasifikasi target output kelas. Penelitian saat ini mengalihfungsikan arsitektur ResNet50 sebagai ekstraktor matriks vektor fitur kemiripan produk.
6	Klasifikasi Jenis Jerawat Secara Otomatis Dengan Convolutional Neural Network Menggunakan Arsitektur ResNet-50	Anshori, dkk.	2025	Ekstraksi fitur ResNet-50 efektif membedakan karakteristik visual kompleks pada kulit berjerawat	Penelitian terdahulu membahas studi kasus penyakit medis. Penelitian saat ini mengeksplorasi studi kasus citra fisik kemasan produk skincare komersial.


2.2 Dasar Teori

Dasar teori disusun untuk memberikan landasan pemikiran yang kuat dan relevan dalam mendukung penelitian ini. Teori-teori yang dibahas menjadi acuan utama dalam memahami konsep, metode, serta pendekatan teknis yang digunakan dalam pengembangan sistem rekomendasi *skincare* berbasis *Hybrid Multimodal*. Dengan adanya landasan teori yang jelas, diharapkan proses penelitian, mulai dari perancangan model hingga evaluasi sistem, dapat berjalan secara sistematis, terarah, dan dapat dipertanggungjawabkan secara ilmiah.

2.2.1 Sistem Rekomendasi

Sistem rekomendasi merupakan sistem yang menerapkan aplikasi dari kecerdasan buatan, dirancang untuk memberikan saran atau rekomendasi item yang paling relevan bagi pengguna berdasarkan preferensi atau riwayat perilakunya. [27]. Dalam industri produk kecantikan, sistem ini sangat dibutuhkan karena banyaknya variasi produk *skincare* seringkali membuat konsumen bingung dalam memilih produk yang tepat (*information overload*). Tujuan utama dari sistem rekomendasi adalah membantu pengguna menemukan produk yang relevan atau dibutuhkan di tengah informasi yang luas dan beragam [27]. Sistem ini bekerja dengan cara memproses data, lalu memprediksi serta menyajikan produk yang paling relevan atau menarik bagi pengguna pada saat tertentu [11].

Penelitian ini menerapkan metode *Content-Based Filtering*. Metode ini bekerja dengan merekomendasikan produk kepada konsumen berdasarkan kemiripan konten atau atribut dengan produk yang disukai sebelumnya [12]. Metode berbasis konten ini secara khusus berfokus pada karakteristik dan atribut dari item yang dicari atau disukai oleh pengguna [27]. Keunggulan utamanya adalah kemampuan untuk memberikan rekomendasi tanpa bergantung pada *rating* dari pengguna lain, melainkan fokus pada spesifikasi produk itu sendiri seperti bahan kandungan dan kategori.



Gambar 2.1. Content-Based Filtering

2.2.2 Hybrid Content-Based Filtering

Hybrid Content-Based Filtering merupakan suatu pendekatan tingkat lanjut dalam sistem rekomendasi yang berfokus pada penggabungan berbagai jenis representasi fitur (*multimodal features*) dari sebuah entitas data [13], [14]. Berdasarkan literatur, pendekatan hibrida pada dasarnya menggabungkan berbagai aspek atau metode yang berbeda dengan tujuan utama untuk meningkatkan keakuratan dan keunikan rekomendasi yang diberikan kepada pengguna [27]. Berbeda dengan pendekatan berbasis konten tradisional yang umumnya beroperasi secara unimodal, yakni hanya mengandalkan satu ekstraksi informasi seperti teks saja atau citra saja, pendekatan hibrida mengintegrasikan berbagai dimensi atribut tersebut ke dalam satu arsitektur terpadu [15]. Secara konseptual, sistem ini bekerja dengan cara mengekstraksi dan mengukur nilai kemiripan (*similarity*) pada masing-masing ruang fitur secara independen menggunakan algoritma metrik komputasi tertentu. Setelah nilai parsial dari setiap modalitas tersebut diperoleh, sistem melakukan fusi tingkat keputusan (*decision-level fusion*) melalui skema pembobotan matematis untuk menghasilkan satu nilai relevansi akhir (*hybrid score*). Integrasi komputasional ini bertujuan untuk menciptakan profil item yang jauh lebih kaya dan komprehensif, sehingga proses pencocokan pola kemiripan dapat dilakukan dengan tingkat kedalaman semantik yang sangat tinggi. Penggabungan metode melalui pendekatan hibrida ini juga diyakini akan semakin

berkembang sebagai solusi untuk memaksimalkan keakuratan dan keterlibatan pengguna terhadap sistem di masa depan [27].

Dalam konteks pengenalan produk fisik yang memiliki spesifikasi khusus, seperti produk perawatan kulit (*skincare*), fusi antara representasi visual dan representasi tekstual menjadi landasan teori yang krusial. Fitur citra berfungsi untuk menangkap karakteristik fisik luar seperti bentuk dan struktur kemasan, sementara fitur teks merepresentasikan informasi tak kasatmata yang fundamental, yaitu komposisi bahan aktif (*ingredients*). Kelebihan utama dari pendekatan *hybrid* multimodal ini terletak pada efek komplementernya dalam meminimalisasi kesenjangan semantik (*semantic gap*) dan bias sistem [26]. Apabila sistem murni bersandar pada fitur citra, terdapat risiko tingginya rekomendasi produk dengan desain kemasan serupa meskipun kandungan kimianya bertolak belakang; sebaliknya, pemrosesan teks semata sering kali terbatas oleh variasi penamaan istilah. Oleh karena itu, dalam kajian teoritis ini, peneliti memformulasikan bahwa integrasi visual dan tekstual dirancang untuk saling menutupi kelemahan inheren dari masing-masing metode tunggal. Pemilihan pendekatan hibrida ini merupakan keputusan strategis yang membentuk dasar kuat untuk implementasi sistem selanjutnya, sehingga sistem untuk mengevaluasi produk secara holistik guna menghasilkan rekomendasi yang jauh lebih presisi dan akurat.

2.2.3 Text Mining dan Preprocessing

Text mining, atau penambangan data teks, adalah proses mengubah teks yang tidak terstruktur menjadi format terstruktur untuk mengidentifikasi pola yang bermakna dan wawasan baru [29]. Dalam konteks rekomendasi produk, teknik ini sangat berharga karena memfasilitasi transformasi dokumen tidak terstruktur (seperti teks komposisi bahan) menjadi format terstruktur yang siap dianalisis dan diproses oleh algoritma machine learning [29].

Sebelum menerapkan algoritma text mining, proses harus dimulai dengan text preprocessing, yaitu praktik membersihkan dan mengubah data teks menjadi format yang dapat digunakan [16]. Praktik ini merupakan aspek inti dari Natural

Language Processing (NLP) guna memformat data agar sesuai untuk dianalisis [29]. Beberapa tahapan teknik ekstraksi dan temu kembali informasi (Information Retrieval) pada pemrosesan teks meliputi:

1. Tokenization Proses memecah teks berformat panjang menjadi kalimat dan kata-kata yang disebut sebagai “token”. Token ini kemudian digunakan dalam model sistem untuk tugas pengelompokan teks maupun pencocokan dokumen.
2. Stemming Proses memisahkan awalan dan akhiran dari kata-kata untuk mendapatkan bentuk dan makna kata dasar (root word). Teknik ini berguna untuk meningkatkan performa temu kembali informasi dengan mengurangi ukuran file indeks.

2.2.4 TF-IDF

Term Frequency-Inverse Document Frequency (TF-IDF) adalah skema pembobotan term yang umum digunakan dalam information retrieval dan klasifikasi dokumen untuk mengubah koleksi dokumen mentah (seperti teks komposisi bahan) menjadi representasi matriks fitur numerik yang dinormalisasi [18], [34]. Dalam ekosistem pustaka komputasi scikit-learn, ekstraksi fitur ini diimplementasikan melalui kelas `TfidfVectorizer`, yang secara fungsional merupakan ekuivalen atau gabungan dari proses perhitungan matriks frekuensi kemunculan kata (`CountVectorizer`) yang dilanjutkan dengan transformasi pembobotan (`TfidfTransformer`) [33].

Tujuan utama dari penggunaan TF-IDF dibandingkan dengan perhitungan frekuensi mentah adalah untuk menurunkan skala atau bobot dampak dari token (kata) yang muncul sangat sering di dalam sebuah korpus [34]. Kata-kata yang terlalu umum ini secara empiris dianggap kurang informatif dibandingkan dengan fitur kata yang hanya muncul pada sebagian kecil populasi dokumen pelatihan [34]. Melalui kelas `TfidfVectorizer`, sistem juga dapat mengontrol ukuran matriks ruang fitur yang dihasilkan, misalnya menggunakan pengaturan `max_features` untuk membangun kosaksata yang hanya mempertimbangkan fitur-fitur teratas

berdasarkan urutan frekuensinya di seluruh dokumen [33].

Di dalam dokumentasi pustaka komputasi tersebut, formulasi yang digunakan untuk menghitung bobot akhir TF-IDF pada suatu kata (term) t dalam dokumen d dinyatakan sebagai perkalian antara komponen Term Frequency (TF) dan Inverse Document Frequency (IDF):

$$tf-idf(t, d) = tf(t, d) \times idf(t) \quad (2-1)$$

Berbeda dengan notasi standar pada buku teks pada umumnya, kalkulasi komponen Inverse Document Frequency (IDF) pada pustaka ini secara baku (default) menerapkan parameter pelembutan atau `smooth_idf=True` [34]. Parameter ini bekerja dengan menambahkan konstanta "1" pada bagian pembilang (numerator) dan penyebut (denominator) dari rumus IDF seolah-olah terdapat satu dokumen ekstra yang berisi setiap term secara persis satu kali. Hal ini bertujuan untuk mencegah terjadinya galat pembagian dengan nol (zero divisions). Rumus kalkulasi IDF tersebut dinyatakan sebagai berikut:

$$idf(t) = \log\left(\frac{1 + n}{1 + df(t)}\right) + 1 \quad (2-1)$$

Keterangan:

1. n : Total jumlah dokumen dalam himpunan data (dataset).
2. $df(t)$: Document frequency, yaitu jumlah dokumen dalam himpunan data yang mengandung kata t .
3. $\log$: Fungsi logaritma natural.
4. 1: Konstanta pelembutan untuk mencegah nol. Nilai 1 yang ditambahkan di luar komponen logaritma memastikan bahwa kata-kata yang muncul di semua dokumen (nilai IDF nol) tidak akan diabaikan sepenuhnya.

Setelah bobot nilai TF-IDF didapatkan, baris keluaran fitur pada matriks


tersebut dinormalisasi secara baku menggunakan metode L2 norm (norm='l2') [33], [34]. Normalisasi ini memastikan bahwa jumlah kuadrat dari elemen vektor bernilai 1. Pendekatan ini sangat penting bagi komputasi sistem rekomendasi, karena dapat digunakan untuk pengukuran metrik cosine similarity antara dua vektor untuk dapat dieksekusi secara langsung menggunakan operasi perkalian titik (dot product) setelah L2 norm diaplikasikan [33], [34].

2.2.5 Convolutional Neural Network (CNN)

Convolutional Neural Network (CNN atau ConvNet) adalah arsitektur jaringan saraf tiruan yang secara eksplisit berasumsi bahwa data masukannya berupa citra digital. Asumsi ini memfasilitasi model untuk mengodekan properti visual tertentu ke dalam arsitekturnya, sehingga proses komputasi (forward function) menjadi lebih efisien dan secara drastis mengurangi jumlah parameter jaringan yang dibutuhkan dibandingkan dengan jaringan saraf biasa [36].

Perbedaan utama arsitektur ini terletak pada susunan neuronnnya. Lapisan (layer) pada CNN memiliki neuron yang disusun dalam 3 dimensi spasial, yaitu panjang (width), lebar (height), dan kedalaman (depth atau jumlah saluran/channel). Setiap lapisan dalam CNN bertugas mentransformasi volume 3 dimensi dari masukan menjadi volume 3 dimensi luaran melalui suatu fungsi komputasi yang dapat didiferensiasi [36].

Secara umum, arsitektur CNN dibangun dengan menumpuk dan merangkai beberapa tipe lapisan utama berikut untuk membentuk sebuah model ekstraksi utuh [19], [21]:



Gambar 2.2 Convolutional Neural network (CNN)

1. *Input Layer* Menyimpan nilai piksel mentah dari citra (seperti matriks gambar kemasan produk), yang direpresentasikan secara spasial dengan dimensi panjang, lebar, dan tiga saluran warna utama (RGB).
2. *Convolutional Layer* Merupakan blok bangunan inti (core building block) dari CNN yang melakukan sebagian besar beban komputasi berat. Lapisan ini menggunakan sekumpulan filter yang dapat dilatih, di mana setiap filter akan digeser (*slide / convolve*) melintasi seluruh lebar dan panjang area masukan. Filter tersebut menghitung perkalian titik (dot product) dengan area lokal di citra untuk menghasilkan peta aktivasi (activation map) dua dimensi.
3. *ReLU Layer* Menerapkan fungsi aktivasi secara elemen (*elementwise*), seperti menetapkan ambang batas pada nilai nol, yaitu $\max(0, x)$. Lapisan ini tidak mengubah ukuran dimensi volume citra secara spasial, melainkan berfungsi mempercepat laju pelatihan.
4. *Pooling Layer* Berfungsi melakukan operasi penurunan ukuran spasial (*downsampling*) di sepanjang dimensi panjang dan lebar secara independen pada setiap irisan kedalaman. Teknik yang paling umum digunakan adalah *Max Pooling*. Proses ini secara progresif mengurangi besaran parameter dan beban komputasi di dalam jaringan, yang pada akhirnya sangat efektif untuk mengontrol risiko *overfitting*.
5. *Fully Connected Layer* Di akhir jaringan, matriks volume didatarkan dan dihubungkan ke lapisan ini. Sesuai dengan namanya, setiap neuron pada lapisan FC terhubung secara penuh ke seluruh aktivasi pada lapisan sebelumnya sama persis dengan prinsip jaringan saraf tiruan biasa untuk mengomputasi keluaran akhir atau representasi fitur citra tersebut.

2.2.6 ResNet50

ResNet-50 (Residual Network) adalah arsitektur jaringan saraf tiruan yang dikembangkan berdasarkan penelitian Deep Residual Learning for Image Recognition [30]. Dalam pengembangan sistem komputasi berbasis pustaka

TorchVision, model ResNet-50 yang diimplementasikan merupakan varian yang dikenal sebagai ResNet V1.5. Varian ini mampu meningkatkan akurasi jaringan dengan memindahkan langkah (stride) untuk proses penurunan dimensi (downsampling) ke konvolusi 3x3 yang kedua, berbeda dengan versi makalah aslinya yang menempatkannya pada konvolusi 1x1 yang pertama [30].

Arsitektur ResNet-50 pada pustaka ini memiliki total 25.557.032 parameter [30]. Arsitektur tersebut memanfaatkan bobot prapelatihan (*pre-trained weights*) standar seperti IMAGENET1K_V1 atau IMAGENET1K_V2 untuk mengekstraksi fitur visual yang kompleks tanpa harus melatih model dari awal. Performa dari bobot prapelatihan tersebut telah diuji secara mendalam pada jutaan data gambar di dalam *dataset* ImageNet-1K [30].

Agar model prapelatih ini dapat bekerja secara optimal dalam membaca matriks gambar kemasan produk, citra masukan harus melewati operasi transformasi pra-pemrosesan (*inference transforms*) yang ketat. Proses ini meliputi pengubahan resolusi gambar (*resize*), pemotongan tepat di area tengah citra (*central crop*) menjadi ukuran matriks 224x224 piksel, dan penskalaan nilai piksel menjadi rentang [0.0, 1.0]. Tahap terakhir adalah menormalisasi nilai tersebut menggunakan nilai rata-rata (*mean*) sebesar [0.485, 0.456, 0.406] dan standar deviasi (*std*) sebesar [0.229, 0.224, 0.225] untuk menstabilkan komputasi ekstraksi fitur [30].

2.2.7 Cosine Similarity

Cosine similarity, atau yang dikenal juga sebagai cosine kernel, adalah metode yang menghitung tingkat kemiripan antar sampel masukan X dan Y [35]. Algoritma ini mengkalkulasi kemiripan sebagai perkalian titik yang dinormalisasi (*normalized dot product*) dari matriks X dan Y [35].

Secara matematis, perhitungan *Cosine Similarity* menggunakan *dot product* dan *magnitude* vektor dirumuskan sebagai berikut:

$$Sim(A, B) = \cos(\theta) = \frac{A \cdot B}{|A| |B|}$$

(2-4)

Persamaan tersebut dijabarkan lebih lanjut ke dalam bentuk operasi sumasi elemen vektor sebagai berikut:

$$Sim(A, B) = \frac{\sum_{i=1}^n A_i B_i}{\sqrt{\sum_{i=1}^n A_i^2} \times \sqrt{\sum_{i=1}^n B_i^2}}$$

(2-5)

Keterangan:

1. $Sim(A, B)$: Nilai kemiripan antara produk dan produk . Nilai yang mendekati 1 menunjukkan bahwa kedua produk sangat mirip, sedangkan nilai 0 menunjukkan tidak ada kemiripan.
2. θ : Sudut yang terbentuk antara dua vektor.
3. A : Vektor representasi fitur dari produk acuan atau target (*query*) yang sedang dicari pengguna.
4. B : Vektor representasi fitur dari produk pembanding yang terdapat di dalam *dataset*.
5. A_i dan B_i : Nilai fitur ke- pada masing-masing vektor. (Berupa bobot kata hasil TF-IDF untuk pengolahan teks, atau nilai piksel ekstraksi ResNet50 untuk pengolahan citra).
6. n : Jumlah total dimensi fitur pada vektor. Dalam sistem ini, perhitungan dilakukan secara terpisah untuk dimensi pada vektor citra dan dimensi pada vektor teks.
7. $A \cdot B$: *Dot product* (perkalian titik) antara vektor dan vektor .
8. $|A|$ dan $|B|$: *Magnitude* (panjang) dari masing-masing vektor dan .

Berdasarkan dokumentasi pustaka komputasinya, pada data masukan yang telah melalui normalisasi L2 (L2-normalized data), fungsi cosine similarity ini secara ekuivalen setara dengan fungsi linear kernel [35].

Parameter masukan dari fungsi ini berupa data berformat matriks padat

(array-like) atau renggang (sparse matrix) X dengan ukuran $(n_samples_X, n_features)$ dan matriks Y dengan ukuran $(n_samples_Y, n_features)$. Apabila nilai Y tidak didefinisikan (None), maka luaran yang dihasilkan adalah tingkat kemiripan berpasangan (pairwise similarities) antara seluruh sampel yang ada di dalam matriks X [35]. Hasil akhir dari eksekusi fungsi ini berupa ndarray atau sparse matrix yang memuat skor kemiripan cosine antar sampel tersebut [35].

2.2.8 Evaluasi Sistem

Untuk mengukur kinerja sistem rekomendasi yang dibangun tanpa label kelas (*unsupervised*), digunakan metrik evaluasi sebagai berikut:

a. Precision@K

Precision secara umum adalah metrik evaluasi yang mengukur proporsi item yang relevan terhadap total keseluruhan item yang direkomendasikan oleh sistem. Semakin tinggi nilai *precision*, maka semakin baik sistem tersebut dalam memberikan rekomendasi yang tepat dan sesuai dengan kebutuhan pengguna [23]. Dalam konteks penelitian ini, digunakan variasi metrik *Precision@K* untuk mengukur akurasi secara fungsional. Pengukuran dilakukan dengan memeriksa kesamaan kategori antara produk acuan (*query*) dengan produk hasil rekomendasi pada peringkat K teratas. Rumus perhitungannya dapat dinyatakan sebagai berikut:

$$Precision@K = \left(\frac{Jumlah\ Item\ Relevan\ di\ Top - K}{K} \right) \times 100\% \quad (2-6)$$

Keterangan:

1. *Precision@K* : Nilai persentase akurasi atau ketepatan sistem dalam memberikan rekomendasi produk pada peringkat teratas.
2. *Jumlah Item Relevan di Top - K* : Jumlah produk hasil rekomendasi yang benar-benar relevan atau sesuai. Dalam konteks penelitian Anda, sebuah produk dihitung relevan apabila produk tersebut memiliki label

kategori yang sama dengan produk acuan (*query*) yang sedang dicari oleh pengguna.

3. K : Batas jumlah maksimal produk yang ditampilkan atau direkomendasikan oleh sistem kepada pengguna. (Contohnya, jika Anda ingin menampilkan *Top-5* rekomendasi, maka nilai adalah 5).
4. 100% : Angka pengali untuk menyajikan hasil perbandingan ke dalam bentuk persentase.

b. Silhouette Score

Silhouette Score (atau Koefisien Silhouette) adalah metode evaluasi yang digunakan ketika label kebenaran dasar (ground truth) dari suatu data tidak diketahui, sehingga evaluasi harus dilakukan menggunakan model itu sendiri [32]. Metrik ini digunakan untuk mengukur kualitas pengelompokan, di mana nilai koefisien yang lebih tinggi menunjukkan bahwa model memiliki definisi kluster yang lebih baik, padat (dense), dan terpisah dengan jelas [32]. Dalam penelitian ini, metrik ini digunakan secara spesifik untuk mengevaluasi validitas dan kualitas pengelompokan (clustering) dari matriks vektor fitur gabungan (hibrida).

Nilai Silhouette Score dibatasi pada rentang -1 hingga +1 [32]. Nilai positif yang mendekati +1 menunjukkan bahwa produk berada dalam kluster yang sangat padat dan terpisah jauh dari kluster lain [32]. Nilai di sekitar angka nol mengindikasikan bahwa batas antar kategori produk saling tumpang tindih (overlapping clusters), sedangkan nilai negatif seperti -1 mengindikasikan pengelompokan yang salah [32]. Koefisien Silhouette untuk satu sampel data individu didefinisikan melalui rumus berikut:

$$S_i = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}} \quad (2-7)$$

Keterangan:

1. S_i : Nilai *Silhouette Score* untuk objek (produk) ke- i .


2. $a(i)$: Rata-rata jarak dari objek ke seluruh objek lain di dalam klaster yang sama (*intra-cluster distance*). Ini merepresentasikan seberapa dekat/cocok produk tersebut dengan kelompoknya sendiri (semakin kecil nilainya, semakin baik).
3. $b(i)$: Rata-rata jarak dari objek ke seluruh objek di dalam klaster tetangga yang paling dekat (*inter-cluster distance*). Ini merepresentasikan seberapa jauh produk tersebut dari kelompok kategori produk lain (semakin besar nilainya, semakin terpisah klasternya).
4. $\max\{a(i), b(i)\}$: Nilai tertinggi (maksimum) di antara jarak dan. Komponen ini bertugas sebagai pembagi untuk menormalisasi hasil akhir sehingga nilai skor selalu konsisten berada pada rentang -1 hingga 1.

c. Visualisasi t-SNE

t-Distributed Stochastic Neighbor Embedding (t-SNE) adalah algoritma reduksi dimensi yang digunakan sebagai alat untuk memvisualisasikan data berdimensi tinggi ke dalam ruang representasi berdimensi rendah (seperti grafik 2 dimensi) [31]. Algoritma ini bekerja secara matematis dengan mengonversi tingkat kemiripan antar titik data menjadi probabilitas gabungan (joint probabilities), kemudian meminimalkan nilai Kullback-Leibler divergence antara probabilitas gabungan dari embedding berdimensi rendah terhadap data berdimensi tingginya [22].

Secara komputasional, sangat disarankan untuk menggunakan metode reduksi dimensi lain terlebih dahulu, seperti Principal Component Analysis (PCA), guna meringkas jumlah dimensi ke tingkat yang wajar (misalnya 50 dimensi) sebelum data dieksekusi oleh t-SNE. Langkah ini krusial untuk menekan derau (noise) serta mempercepat proses komputasi jarak berpasangan antar sampel data [31]. Pada sistem rekomendasi skincare ini, pemetaan t-SNE dilakukan untuk mengamati pola pengelompokan produk secara visual. Jika titik-titik data produk dengan kategori yang sama terlihat menggerombol atau berkumpul (clustering) pada grafik, hal tersebut menjadi indikator visual bahwa sistem telah berhasil

mengeksktraksi dan mengenali pola kemiripan produk dengan baik.



Gambar 2.3 Contoh Visualisasi t-SNE

BAB III METODE PENELITIAN

3.1 Objek Penelitian

Objek utama penelitian berupa himpunan data produk skincare. Himpunan data bersumber repositori dataset publik SkinSafe Kaggle. Populasi data mencakup 4.800 sampel produk. Fokus pengolahan bertumpu pada dua elemen utama spesifikasi produk. Elemen pertama berupa berkas citra digital kemasan fisik produk. Elemen ini beroperasi sebagai masukan proses ekstraksi fitur visual arsitektur ResNet50. Elemen kedua berupa teks daftar komposisi bahan penyusun produk. Elemen ini beroperasi sebagai masukan tahapan pembobotan kata metode TF-IDF. Penelitian ini meniadakan pelibatan interaksi pengguna platform belanja daring sebagai subjek observasi. Seluruh proses komputasi murni mengeksplorasi atribut intrinsik produk. Tabel 3.1 menyajikan satu sampel baris data representatif berdasar struktur atribut sistem.

Tabel 3.1 Sampel Data Objek Penelitian

no	product_name	brand	usage_type	category	ingredients	image_url
1	No7 Hydra Luminous Aqua Release Skin Perfector Tinted Moisturiser, Medium, 1 fl oz/30 mL	No7	Face	Tinted Moisturizers	Propylene Glycol, Alcohol Denat., Anhydroxylitol, Aqua (Water), Butylene Glycol, Caprylyl Methicone, Cetyl Peg/Ppg-10/1 Dimethicone, Ci 77891 (Titanium Dioxide), Ci77491, Ci 77492, Ci 77499 (Iron Oxides), Ethyl Paraben, Glucose, Glycerin, Magnesium Sulfate, Methylparaben, Mica, Morus Alba Leaf Extract, Panax Ginseng Root Extract, Panthenol, Pentaerythrityl Tetra-Di-T-Butyl Hydroxyhydrocinnamate,	https://cdn.l.skinsafeproducts.com/photo/E847973DCD947F/large_1675053253.png?1675053253

					Phenoxyethanol, Tetrasodium Edta, Tocopherol Acetate, Triethoxycaprylylsilane, Xylitol, Xylitylglucoside	
2	Tower 28 SOS Daily Rescue Facial Spray, 4 fl oz/120 mL	Tower 28	Face	Spray Moisturizer	Hypochlorous Acid, Sodium Chloride, Water	https://cdn.l.skinsafeproducts.com/photo/4880263F320977/large_1747133676.pngpng?1747133676
3	Clinique Takes the Day Off Cleansing Oil, 6.7 fl oz/200 mL	Clinique	Facial	Cleansing Oil	Bht, Caprylyl Glycol, Cetyl Ethylhexanoate, Glycerin, Glyceryl Laurate, Peg-12 Diisostearate, Peg-20 Glyceryl Triisostearate, Peg-8 Diisostearate, Polybutene, Ppg-15 Stearyl Ether, Tocopheryl Acetate, Triethylhexanoin, Water\Aqua\Eau	https://cdn.l.skinsafeproducts.com/photo/53EEB43B6175C1/large_1742900375.pngpng?1742900375
4	Necessaire The Body Lotion, Fragrance Free, 15.2 fl oz/450 mL	Necessaire	Body	Lotions	Aqua/Water/Eau, Caprylhydroxamic Acid, Caprylic/Capric Triglyceride, Caprylyl Glycol, Caryodendron Orinocense Seed Oil, Cetearyl Alcohol, Cetearyl Oliviate, Dicaprylyl Carbonate, Glycerin, Glyceryl Stearate, Limnantes Alba (Meadowfoam) Seed Oil, Linoleic Acid, Linolenic Acid, Niacinamide,	https://cdn.l.skinsafeproducts.com/photo/D9ADD5E089E1AD/large_1742574438.jpeg?1742574438

					Oleic Acid, Palmitic Acid, Palmitoyl Dipeptide-5 Diaminobutyroyl Hydroxythreonine, Palmitoyl Dipeptide-5 Diaminohydroxybutyrate, Palmitoyl Hexapeptide-12, Palmitoyl Tetrapeptide-7, Palmitoyl Tripeptide-1, Polyacrylate Crosspolymer-6, Propanediol, Sclerocarya Birrea Seed Oil, Shea Butter Glycerides, Simmondsia Chinensis (Jojoba) Seed Oil, Stearic Acid, T-Butyl Alcohol, Tocopherol, Xanthan Gum	
5	Paula's Choice Resist Weightless Advanced Repairing Toner, 4 fl oz/118 mL	Paula's Choice	Toners & Astringents	Toners	Acetyl Glucosamine, Adenosine, Butylene Glycol, Carbomer, Carnosine, Citric Acid, Epigallocatechin Gallate, Ethoxydiglycol, Ethylhexylglycerin, Genistein, Glycerin, Glycyrrhiza Glabra, Niacinamide, Palmitoyl Tetrapeptide-7, Palmitoyl Tripeptide-1, Phenoxyethanol, Phospholipid, Polysorbate 20, Resveratrol, Salix Nigra (Willow) Bark Extract, Sodium Hyaluronate, Tetrasodium Edta, Water, Xanthan Gum	https://cdn.l.skinsafeproducts.com/photo/2A9B12AC8F660B/large_1741755457.png?1741755457
6	Aestura Atobarrier365 Moisturizing Cream,	AESTURA	Face	Creams	Acrylates/Ammonium Methacrylate Copolymer, Allantoin, Arachidic Acid, Arachidyl Alcohol, Arachidyl Glucoside, Behenyl Alcohol, Betaine, Butylene Glycol, Butylene	https://cdn.l.skinsafeproducts.com/photo/DCEE5F4F5

	Ceramide, 1.52 fl oz/45 mL				Glycol Dicaprylate/Dicaprate, C12-20 Alkyl Glucoside, C14-22 Alcohols, Carbomer, Ceramide Np, Cetyl Ethylhexanoate, Cholesterol, Dicaprylyl Carbonate, Dimethicone, Dimethiconol, Ethylhexyl Palmitate, Ethylhexylglycerin, Glycerin, Glyceryl Caprylate, Hydrogenated Lecithin, Hydrogenated Polyisobutene, Hydroxypropyl Bislauramide Mea, Hydroxypropyl Bispalmitamide Mea, Mannitol, Niacinamide, Oleic Acid, Palmitic Acid, Pentaerythrityl Tetraistearate, Phytosphingosine, Polyacrylate-13, Polyglyceryl-10 Laurate, Silica, Sorbitan Isostearate, Sphingolipids, Squalane, Stearic Acid, Tocopherol, Tromethamine, Water/Aqua/Eau	63D22/large_1740118842.jpeg?1740118842
7	Clinique All About Eyes Cream, Vitamin C, 1 oz/30 mL	Clinique	Eye Cream, Gel, Oils, & Serum	Creams	Butylene Glycol, Caffeine, Camellia Sinensis (Green Tea) Leaf Extract, Cetyl Peg/Ppg-10/1 Dimethicone, Cholesterol, Cyclopentasiloxane, Dimethicone, Disodium Edta, Ethylene/Acrylic Acid Copolymer, Glycerin, Glyceryl Laurate, Iron Oxides (Ci 77491, Ci 77492, Ci 77499), Isostearyl Palmitate, Linoleic Acid, Magnesium Ascorbyl Phosphate, Morus Bombicis (Mulberry) Root Extract, Olea Europaea (Olive) Fruit Extract, Peg/Ppg-18/18 Dimethicone, Petrolatum, Phytosphingosine, Polyethylene,	https://cdn1.skinfo.net/products/clinique/photo/08_FEBD34B370B5/large_1739945549.png?1739945549

					Polysilicone-11, Propylene Carbonate, Pyridoxine Dipalmitate, Quaternium-18 Bentonite, Scutellaria Baicalensis Root Extract, Sodium Chloride, Sodium Metabisulfite, Sodium Sulfite, Sucrose, Tocopheryl Acetate, Triticum Vulgare (Wheat Bran) Extract, Water\Aqua\Eau, Whey Protein\Lactis Protein\Proteine Du Petit-Lait	
8	The Ordinary A High-Strength Serum, Alpha Arbutin 2% + Ha, 1 fl oz/30 mL	The Ordinary	Skin Treatments	Serums	Alpha-Arbutin, Aqua (Water), Chlorphenesin, Citric Acid, Ethoxydiglycol, Ethoxydiglycol, Hydrolyzed Sodium Hyaluronate, Phenoxyethanol, Polyacrylate Crosspolymer-6, Polysorbate 20, Propanediol, Sodium Citrate, Sodium Hydroxide, Sodium Metabisulfite, Trisodium Ethylenediamine Disuccinate	https://cdn.l.skinsafep.roducts.com/photo/0/AEE1CF0720FA0/large_1739422596.png?1739422596
9	Mario Badescu Skin Care Deep Blemish Solution, 1 fl oz/29 mL	Mario Badescu Skin Care	Skin Care	Skin Treatments	Propylene Glycol, Allantoin, Biotin, Citric Acid, Disodium Phosphate, Glycerin, Hydrolyzed Yeast Protein, Isopropyl Alcohol, Isopropyl Myristate, Lactic Acid, Niacinamide, Panthenol, Phenoxyethanol, Potassium Sorbate, Propylene Carbonate, Pyridoxine Hcl, Sodium Hydroxide, Stearalkonium Hectorite, Threonine, Water (Aqua/Eau), Zinc Oxide	https://cdn.l.skinsafep.roducts.com/photo/F53752E2767BB0/large_1734037316.jpeg?1734037316


10	Roc Line Smoothing Eye Cream, Retinol Correxion, 0.5 fl oz/15 mL	ROC	Eye Crea m, Gel, Oils, & Seru m	Creams	Ascorbic Acid, Bht, C12-15 Alkyl Benzoate, Carbomer, Cetearyl Ethylhexanoate, Chlorhexidine Digluconate, Citric Acid, Copper Gluconate, Dihydroxy Methylchromone, Disodium Edta, Ethylhexylglycerin, Glycerin, Glyceryl Stearate, Isopropyl Myristate, Lactose, Magnesium Aspartate, Methyl Methacrylate/Glycol Dimethacrylate Crosspolymer, Panthenol, Peg-100 Stearate, Peg-8, Phenoxyethanol, Polysorbate 20, Propyl Gallate, Retinol, Sorbitol, Stearyl Alcohol, Tocopheryl Acetate, Tromethamine, Water/Aqua/Eau, Zinc Gluconate	https://cdn1.skinsafeproduts.com/photo/DB7094A5340E81/large_1734187371.png
11	Neostrata Hyaluronic Luminous Lift Daily Volumizing Gel Cream, 1.7 oz/50 g	NeoS trata	Face	Creams	1,2-Hexanediol, Acetyl Glucosamine, Aqua/Water/Eau, Caprylyl Glycol, Cetearyl Olivat, Chlorphenesin, Dimethicone, Dimethicone Crosspolymer, Dimethiconol, Ethylhexyl Stearate, Glycerin, Glyceryl Dilaurate, Hydrolyzed Sodium Hyaluronate, Hydroxyethyl Acrylate/Sodium Acryloyldimethyl Taurate Copolymer, Lactic Acid, Phenoxyethanol, Polyglyceryl-4 Diisostearate/Polyhydroxystearate/ Sebacate, Sclerotium Gum, Sodium Hyaluronate, Sodium Hyaluronate Crosspolymer, Sodium Isostearate,	https://cdn1.skinsafeproduts.com/photo/B7B7AA6E14CB29/large_1733982323.jpeg

					Sodium Lactate, Sorbitan Olivatate, Steareth-10, Yeast Extract	
12	Minimalist Niacinamide 05% Body t Lotion, Glycerin 20% + Shea Butter + Betaine, 6.3 oz/180 g	Minimalist	Body	Lotions	Propylene Glycol, Aqua, Betaine, Butyrospermum Parkii (Shea) Butter, C12-15 Alkyl Benzoate, C9-12 Alkane, Caprylic/Capric Triglyceride, Carbomer, Cetearyl Alcohol, Coco-Caprylate/Caprates, Dicaprylyl/Dicaprate, Diisopropyl Adipate, Diisopropyl Sebacate, Ethylhexylglycerin, Glycerin, Glyceryl Stearate, Hydrogenated Polyisobutene, Hydroxyethyl Acrylate/Sodium Acryloyldimethyl Taurate Copolymer, Isododecane, Niacinamide, Peg-100 Stearate, Petrolatum, Phenoxyethanol, Polyurethane-100, Triethanolamine, Triheptanoin, Trisodium Ethylenediamine Disuccinate	https://cdn.l.skinsafeproducts.com/photo/655D1B8717DC96/large_1730660569.jpeg?1730660569
13	SK-II Brightening Derm Revival Masks, 10 Count	SK-II	Skin Treatments	Facial Masks	Acrylates/C10-30 Alkyl Acrylate Crosspolymer, Ascorbyl Glucoside, Benzyl Alcohol, Butylene Glycol, Disodium Edta, Galactomyces Ferment Filtrate, Glycerin, Inositol, Methylparaben, Niacinamide, Pentylene Glycol, Phenoxyethanol, Sodium Hydroxide, Water, Yeast Extract	https://cdn.l.skinsafeproducts.com/photo/77BE7E9BB88C1B/large_1731099267.jpeg?1731099267
14	Chanel La Solution 10 De Chanel Sensitive	Chanel	Face	Creams	Aqua (Water), Butyrospermum Parkii (Shea) Butter Extract, Camellia Sinensis Leaf Extract, Caprylyl Glycol, Glycerin, Lauroyl	https://cdn.l.skinsafeproducts.com/photo/F

	Skin Cream, 1.7 fl oz/50 mL				Lysine, Phenoxyethanol, Sodium Polyacrylate, Squalane, Steareth-21	EC4512B45ACF9/large_1733043462.png?1733043462
15	IsNtree Aloe Fresh Type Soothing Gel, 10.14 fl oz/300 mL	IsNtree	Body	Gels	1,2-Hexanediol, Allantoin, Aloe Barbadensis Leaf Extract, Arginine, Betaine, Carbomer, Dipotassium Glycyrrhizate, Ethylhexylglycerin, Glycerin, Panthenol, Propanediol, Sodium Hyaluronate	https://cdn.l.skinsafeproducts.com/photo/EC7A9C83DBA97C/large_1732606113.png?1732606113

3.2 Alur Penelitian

Prosedur ini dilaksanakan secara bertahap dan sistematis untuk memastikan tujuan penelitian tercapai. Urutan langkah-langkah penelitian divisualisasikan dalam bentuk bagan alir (*flowchart*) sebagaimana terlihat pada gambar 3.1.



Gambar 3.1 Alur Penelitian

Adapun penjelasan mengenai setiap tahapan dalam alur penelitian disajikan sebagai berikut:

1. Pengumpulan Data

Pengumpulan Data dilakukan dengan mengakuisisi data mentah sekunder berupa gambar fisik kemasan dan teks daftar komposisi bahan produk skincare dari dataset publik SkinSafe di Kaggle.

2. Preprocessing Data

Preprocessing Data dilakukan dengan menormalisasi dimensi gambar kemasan menjadi matriks seragam (224x224 piksel) serta membersihkan teks komposisi bahan dari karakter derau agar data siap diolah oleh model.

3. ResNet50

ResNet50 dilakukan dengan memproses data gambar secara paralel menggunakan arsitektur pre-trained ResNet50 untuk mengekstraksi dan mendapatkan vektor fitur visual produk.

4. TF-IDF

TF-IDF dilakukan dengan memproses data teks secara paralel menggunakan algoritma Term Frequency-Inverse Document Frequency (TF-IDF) untuk mengekstraksi dan mendapatkan pembobotan kata atau matriks vektor fitur tekstual.

5. Cosine Similarity

Cosine Similarity dilakukan dengan menggabungkan (concatenation) kedua representasi fitur (visual dan teks) tersebut, lalu dihitung derajat kemiripannya dengan mengukur jarak sudut kosinus antar produk.

6. Sistem Rekomendasi

Sistem Rekomendasi dilakukan dengan menyusun urutan produk berdasarkan derajat skor kemiripan tertinggi untuk menyeleksi dan menghasilkan daftar lima produk alternatif teratas (Top-5) sebagai rekomendasi.

7. Evaluasi

Evaluasi dilakukan dengan mengukur kinerja akurasi algoritma menggunakan metrik Precision@5, memvalidasi batas klaster data dengan perhitungan Silhouette Score, serta memvisualisasikan sebaran data menggunakan algoritma t-SNE. Apabila hasil evaluasi belum memenuhi kriteria, sistem akan melalui tahapan iterasi berupa perbaikan parameter atau model, yang kemudian diekstraksi dan dievaluasi kembali hingga mencapai hasil yang optimal.

8. Deployment

Deployment dilakukan dengan merilis dan mengintegrasikan seluruh logika pemrograman ke dalam bentuk prototype aplikasi web interaktif menggunakan framework Streamlit

3.3 Alat dan Bahan

Dalam penelitian ini, akan menggunakan beberapa sarana pendukung seperti perangkat keras (*hardware*), perangkat lunak (*software*), serta bahan penelitian berupa *dataset*. Adapun rincian alat dan bahan yang digunakan adalah sebagai berikut:

3.3.1 Perangkat Keras (Hardware)

Perangkat keras yang digunakan dalam penelitian ini berfungsi untuk melakukan pengolahan data, pengkodean algoritma, hingga penyusunan laporan. Spesifikasi perangkat keras yang digunakan meliputi:

1. Laptop atau komputer desktop dengan spesifikasi lokal, yaitu menggunakan Prosesor Intel(R) Core (TM) i3-3240 CPU @ 3.40GHz dan RAM 8.00 GB untuk kelancaran dalam proses komputasi ringan, pengembangan antarmuka, dan penyusunan laporan.
2. Komputasi *Cloud* (Akselerator Perangkat Keras), menggunakan spesifikasi *server cloud* berupa GPU (Graphics Processing Unit) atau TPU (Tensor Processing Unit) yang diakses secara virtual melalui layanan Google Colab. Akselerator ini difungsikan khusus untuk menangani beban komputasi tinggi pada saat proses ekstraksi fitur citra kemasan produk menggunakan arsitektur *Deep Learning* ResNet-50.

3.3.2 Perangkat Lunak (Software)

Perangkat lunak digunakan dalam proses implementasi sistem rekomendasi *Hybrid* (ResNet-50 dan TF-IDF) serta pengolahan data. Perangkat lunak yang digunakan adalah:

1. Sistem Operasi Windows 10 atau Windows 11 (64-bit).
2. Bahasa Pemrograman Python (versi 3.8 atau versi terbaru).
3. Lingkungan Pengembangan (IDE) menggunakan:
 - 1) Visual Studio Code (VS Code), yang digunakan untuk menulis dan menjalankan skrip Python serta membangun aplikasi antarmuka sistem (*web*) secara lokal.

- 2) Google Colaboratory (Google Colab), digunakan sebagai lingkungan pengembangan berbasis *cloud* (Jupyter Notebook) untuk melakukan *preprocessing* data dan melatih model *Deep Learning* (ResNet-50 dan TF-IDF) tanpa membebani memori penyimpanan perangkat lokal.
4. *Library* Python meliputi: Pandas dan NumPy yang digunakan untuk manipulasi data; TensorFlow/Keras yang digunakan untuk menjalankan model *Deep Learning* ResNet-50; Scikit-learn yang digunakan untuk implementasi algoritma TF-IDF, perhitungan *Cosine Similarity*, serta evaluasi model (Silhouette Score dan t-SNE); dan Streamlit yang digunakan untuk membuat aplikasi *web* interaktif.
5. *Web Browser* (Google Chrome/Microsoft Edge) untuk mengakses referensi penelitian, layanan Google Colab, dan mengunduh *dataset*.

3.3.3 Bahan penelitian

Bahan utama dalam penelitian ini adalah data sekunder berupa *dataset* SkinSafe edisi tahun 2025 yang diperoleh melalui portal publik Kaggle. Spesifikasi bahan penelitian ini meliputi:

1. *Dataset* yang berisi seluruh atribut yang dibutuhkan secara lengkap, yaitu atribut data citra (*image*) dan atribut data teks (komposisi bahan).

BAB IV HASIL DAN PEMBAHASAN

4.1 Pengumpulan Data

Peneliti mengunduh himpunan data sekunder produk perawatan kulit. Sumber data berasal dari repositori publik Kaggle. Dataset ini bernama SkinSafe Skincare DB. Populasi dataset memuat lebih dari lima puluh ribu produk. Data tersebut tersebar ke dalam dua belas berkas berekstensi CSV. Peneliti menerapkan teknik pemotongan populasi data. Pemotongan ini bertujuan membatasi beban komputasi perangkat keras.

Peneliti hanya mengambil satu berkas CSV pertama. Berkas ini memuat sampel sebanyak 4.800 produk. Jumlah ini merepresentasikan keragaman populasi produk secara proporsional. Setiap baris data memuat atribut teks komposisi bahan. Baris data juga memuat tautan referensi gambar kemasan fisik. Tabel 4.1 menampilkan struktur atribut himpunan data tersebut.

Tabel 4.1 Struktur Atribut Data

Nama Atribut	Tipe Data	Deskripsi
product_name	String (Teks)	Menyimpan informasi nama atau judul spesifik dari produk skincare.
brand	String (Teks)	Menyimpan informasi merek dagang atau produsen pembuat produk.
usage_type	String (Teks)	Menyimpan informasi mengenai jenis atau tata cara penggunaan produk.
category	String (Teks)	Menyimpan informasi klasifikasi atau kategori produk (misalnya: Serum, Moisturizer).

ingredients	String (Teks)	Menyimpan daftar teks komposisi bahan pembentuk produk dengan standar INCI.
image_url	String (Teks)	Menyimpan tautan referensi (link) untuk mengunduh gambar visual dari produk.
product_url	String (Teks)	Menyimpan tautan halaman produk asli pada situs SkinSafe.com untuk referensi data.

4.2 Preprocessing Data

Tahap ini membersihkan himpunan data mentah. Pembersihan ini menghilangkan derau atribut masukan sistem. Data kotor berpotensi mendistorsi hasil kalkulasi tingkat kemiripan antar produk. Distorsi ini menurunkan performa akurasi sistem secara keseluruhan. Peneliti mengeksekusi serangkaian prosedur sistematis.

Prosedur pertama melibatkan pembersihan struktur data. Prosedur kedua menormalisasi teks daftar komposisi bahan. Prosedur ketiga mengakuisisi berkas citra digital fisik. Proses ini menjamin integritas entitas data masukan sistem. Data bersih mengoptimalkan kinerja arsitektur ResNet50. Data bersih juga mengoptimalkan kinerja algoritma TF-IDF.

4.2.1 Data Cleaning

Tahap ini membersihkan himpunan data mentah. Pembersihan ini menghilangkan derau pada berbagai atribut masukan sistem. Data kotor berpotensi mendistorsi hasil kalkulasi tingkat kemiripan antar produk. Distorsi ini menurunkan performa akurasi sistem secara keseluruhan. Peneliti mengeksekusi serangkaian prosedur sistematis.

a. Handling Duplicates

Tahap ini mengeliminasi baris data ganda pada populasi dataset. Peneliti mengidentifikasi duplikasi memakai atribut tautan produk sebagai kunci unik. Satu

tautan murni merepresentasikan satu halaman produk spesifik pada situs penyedia. Keberadaan data ganda berpotensi mengacaukan matriks kemiripan sistem hibrida.

Penghapusan duplikasi menjamin variasi luaran rekomendasi bagi pengguna akhir. Algoritma pemindaian menyeleksi seluruh baris data secara menyeluruh. Hasil pemindaian membuktikan ketiadaan data ganda pada populasi awal dataset. Populasi data tetap berjumlah 4.787 baris. Tabel 4.2 mendokumentasikan hasil pemrosesan ini.

Tabel 4.2 Hasil Handling Duplicates

Keterangan	Jumlah Data
Data Awal	4787
Penghapusan Data Duplikat	0
Data Final Bersih	4787

b. Handling Missing Values

Peneliti mengeksekusi pembuangan baris data bernilai kosong. Sistem hibrida mewajibkan ketersediaan atribut teks komposisi bahan kimia. Sistem hibrida juga mewajibkan ketersediaan atribut gambar kemasan fisik. Ketidadaan salah satu atribut memutus rantai komputasi fitur multimodal.

Produk tanpa daftar bahan menggagalkan ekstraksi fitur kimiawi algoritma TF-IDF. Produk tanpa gambar menggagalkan ekstraksi fitur visual model ResNet50. Algoritma menghapus setiap baris berstatus tidak lengkap tersebut. Total 4.787 baris data dinyatakan valid berstatus siap proses. Tabel 4.3 menampilkan rincian hasil pemrosesan ini.

Tabel 4.3 Hasil Missing Values

Keterangan	Jumlah Data
Data Awal	4787
Penghapusan Data Duplikat	0
Data Final Bersih	4787

4.2.2 Text Preprocessing

Proses ini menormalisasi atribut teks daftar komposisi bahan kimia. Tujuan utamanya berupa penyiapan teks bersih bagi algoritma pembobotan kata. Tahap ini menjamin ekstraksi fitur tekstual beroperasi secara presisi. Variasi penulisan manual berpotensi mengacaukan kalkulasi bobot kepentingan kata.

a. Case Folding

Proses case folding mengubah seluruh huruf kapital menjadi huruf kecil. Mesin menginterpretasikan huruf kapital secara berbeda dari huruf kecil. Tahap ini merupakan langkah paling awal pada normalisasi teks. Penyeragaman ini mencegah timbulnya redundansi fitur token kosakata.

Kosakata bahan kimia kini memiliki format ukuran huruf seragam. Tahap ini mempermudah proses komputasi pencocokan kemiripan pada tahap selanjutnya. Algoritma pembobotan kata mampu menghitung frekuensi bahan secara akurat. Tabel 4.4 menyajikan hasil implementasi tahap penyeragaman huruf ini.

Tabel 4.4 Hasil Implementasi Tahap Case Folding

Sebelum	Sesudah
Propylene Glycol, Alcohol Denat, Anhydroxylitol, Aqua (Water), Butylene Glycol, Caprylyl Methicone, Cetyl Peg/Ppg-10/1 Dimethicone, Ci 77891 (Titanium Dioxide), Cl77491, Cl 77492, Cl 77499 (Iron Oxides), Ethyl Paraben, Glucose, Glycerin, Magnesium Sulfate, Methylparaben, Mica, Morus Alba Leaf Extract, Panax Ginseng Root Extract, Panthenol, Pentaerythrityl	propylene glycol, alcohol denat, anhydroxylitol, aqua (water), butylene glycol, caprylyl methicone, cetyl peg/ppg-10/1 dimethicone, ci 77891 (titanium dioxide), cl77491, cl 77492, cl 77499 (iron oxides), ethyl paraben, glucose, glycerin, magnesium sulfate, methylparaben, mica, morus alba leaf extract, panax ginseng root extract, panthenol, pentaerythrityl

Tetra-Di-T-Butyl Hydroxyhydrocinnamate, Phenoxyethanol, Tetrasodium Edta, Tocopherol Acetate, Triethoxycaprylylsilane, Xylitol, Xylitylglucoside	tetra-di-t-butyl hydroxyhydrocinnamate, phenoxyethanol, tetrasodium edta, tocopherol acetate, triethoxycaprylylsilane, xylitol, xylitylglucoside
---	---

b. Cleansing

Proses cleansing membuang karakter derau bermakna kosong pada teks. Pembersihan ini menghilangkan seluruh kemunculan karakter angka desimal. Pembersihan ini juga menghilangkan berbagai simbol tanda baca khusus. Peneliti mengeksekusi pembersihan ini memakai teknik ekspresi reguler.

Tahap ini mempertahankan deretan alfabet pembentuk nama bahan kimia. Tanda koma tetap dipertahankan sebagai pembatas antar token kosakata. Kosakata bersih mempermudah proses pembobotan signifikansi sebuah bahan aktif. Tabel 4.5 memperlihatkan wujud teks sesudah melewati proses pembersihan karakter.

Tabel 4.5 Hasil Implementasi Tahap Cleansing

Sebelum	Sesudah
propylene glycol, alcohol denat, anhydroxylitol, aqua (water), butylene glycol, caprylyl methicone, cetyl peg/ppg-10/1 dimethicone, ci 77891 (titanium dioxide), ci77491, ci 77492, ci 77499 (iron oxides), ethyl paraben, glucose, glycerin, magnesium sulfate, methylparaben, mica, morus alba leaf extract, panax	propylene glycol, alcohol denat, anhydroxylitol, aqua water, butylene glycol, caprylyl methicone, cetyl pegppg dimethicone, ci titanium dioxide, cl, cl , cl iron oxides, ethyl paraben, glucose, glycerin, magnesium sulfate, methylparaben, mica, morus alba leaf extract, panax ginseng root extract,

ginseng root extract, panthenol, pentaerythrityl tetra-di-t-butyl hydroxyhydrocinnamate, phenoxyethanol, tetrasodium edta, tocopherol acetate, triethoxycaprylylsilane, xylitol, xylitylglucoside	panthenol, pentaerythrityl tetraditbutyl hydroxyhydrocinnamate, phenoxyethanol, tetrasodium edta, tocopherol acetate, triethoxycaprylylsilane, xylitol, xylitylglucoside
--	--

c. Whitespace Normalization

Proses whitespace normalization merapikan jarak spasi antar kata. Penghapusan spasi ganda mencegah kesalahan pemotongan token nama bahan. Karakter spasi berlebih pada bagian awal teks langsung dibuang. Karakter spasi berlebih pada bagian akhir teks juga dibuang.

Penataan spasi menjamin jarak antar kata menjadi selalu konsisten. Proses ini menghasilkan matriks teks bersih berformat baku. Data ini menjadi masukan utama algoritma pembobotan kata TF-IDF. Tabel 4.6 mendokumentasikan hasil normalisasi spasi pada sampel komposisi.

Tabel 4.6 Hasil Whitespace Normalization

Sebelum	Sesudah
propylene glycol, alcohol denat, anhydroxylitol, aqua water, butylene glycol, caprylyl methicone, cetyl pegppg dimethicone, ci titanium dioxide, cl, cl, cl iron oxides, ethyl paraben, glucose, glycerin, magnesium sulfate, methylparaben, mica, morus	propylene glycol, alcohol denat, anhydroxylitol, aqua water, butylene glycol, caprylyl methicone, cetyl pegppg dimethicone, ci titanium dioxide, cl, cl, cl iron oxides, ethyl paraben, glucose, glycerin, magnesium sulfate, methylparaben, mica,

alba leaf extract, panax ginseng root extract, panthenol, pentaerythrityl tetraditbutyl hydroxyhydrocinnamate, phenoxyethanol, tetrasodium edta, tocopherol acetate, triethoxycaprylylsilane, xylitol, xylitylglucoside	morus alba leaf extract, panax ginseng root extract, panthenol, pentaerythrityl tetraditbutyl hydroxyhydrocinnamate, phenoxyethanol, tetrasodium edta, tocopherol acetate, triethoxycaprylylsilane, xylitol, xylitylglucoside
--	---

4.2.3 Image Preprocessing

Tahap ini mengakuisisi berkas citra digital kemasan produk perawatan kulit. Dataset awal murni menyediakan teks tautan referensi alamat gambar. Peneliti mengeksekusi skrip pengunduh otomatis berbasis bahasa pemrograman Python. Skrip ini mengakses setiap tautan referensi tersebut secara berurutan. Gambar berstatus sukses unduh tersimpan pada direktori memori perangkat lokal. Penamaan berkas fisik mengikuti format sistematis tertentu berdasar nomor identitas. Peneliti mencatat lokasi penyimpanan berkas fisik ini ke dalam kolom atribut baru. Atribut baru ini merepresentasikan alamat akses mesin saat proses ekstraksi beroperasi.

Peneliti mengevaluasi status keberhasilan proses unduh keseluruhan gambar. Sistem menghapus baris data berstatus tautan mati. Penghapusan ini mencegah kegagalan fatal pada proses komputasi ekstraksi fitur visual. Normalisasi dimensi gambar dieksekusi pasca proses akuisisi selesai. Resolusi seluruh gambar diubah menjadi matriks berukuran seragam. Resolusi baru bernilai 224x224 piksel pada setiap sisi. Ukuran baku ini mengikuti standar masukan wajib arsitektur ResNet50. Proses ini menghasilkan koleksi citra bersih. Tabel 4.7 menyajikan bukti keberhasilan proses akuisisi ini.

Tabel 4.7 Bukti Akuisisi dan Validasi Lokasi Citra Lokal

Sebelum	Sesudah
https://cdn1.skincareproducts.com/photo/E847973DCD947F/large_1675053253.png	
https://cdn1.skincareproducts.com/photo/4880263F320977/large_1747133676.png	

4.3 Ekstraksi Fitur

Tahapan ekstraksi fitur dalam penelitian ini dibagi menjadi dua bagian utama sesuai dengan pendekatan *multimodal* yang digunakan, yaitu pengolahan data visual (citra) dan data tekstual. Fitur visual kemasan produk diekstraksi menggunakan arsitektur *deep learning* ResNet-50, sedangkan fitur tekstual yang berupa kandungan bahan (*ingredients*) diekstraksi menggunakan metode TF-IDF untuk menghasilkan representasi vektor numerik yang siap diproses pada tahap selanjutnya.

4.3.1 ResNet 50

Ekstraksi fitur citra pada penelitian ini dilakukan menggunakan arsitektur model *Convolutional Neural Network* (CNN) ResNet50 yang telah melalui proses prapemrosesan (*pre-trained*) menggunakan dataset ImageNet [20]. Peneliti melakukan proses ekstraksi secara langsung pada setiap citra fisik produk *skincare* yang dirujuk melalui atribut `image_path`. Data citra tersebut dipastikan telah tervalidasi ketersediaannya pada tahapan pra-pemrosesan. Proses implementasi diawali dengan menyesuaikan resolusi asli citra (*resize*) menjadi dimensi standar yang diterima oleh model ResNet50, yaitu berukuran 224 X 224 piksel. Selanjutnya, citra diubah ke dalam bentuk larik numerik dan diproses menggunakan fungsi `preprocess_input`. Fungsi ini bertugas melakukan standarisasi skala nilai

piksel dan penyesuaian *channel* warna citra agar relevan dengan kondisi distribusi data saat model ResNet50 pertama kali dilatih.

Dalam implementasi model ini, peneliti menggunakan konfigurasi parameter *include_top=False* guna mengeliminasi lapisan klasifikasi akhir model, serta menerapkan parameter *pooling='avg'* untuk menjalankan teknik *Global Average Pooling* pada lapisan ekstraksi terakhir. Penerapan metode *pooling* ini secara konsisten mengonversi *feature map* yang kompleks menjadi sebuah vektor fitur numerik tunggal berdimensi 2048. Nilai-nilai dalam dimensi 2048 tersebut merupakan representasi matematis dari karakteristik pola visual produk, seperti dominasi warna kemasan, bentuk botol, tekstur label, dan atribut fisik lainnya. Keseragaman ukuran dimensi sebesar 2048 untuk setiap citra sangat esensial karena merupakan syarat wajib (*prerequisite*) agar vektor fitur tersebut dapat dikalkulasikan secara matematis menggunakan algoritma *Cosine Similarity* pada tahapan selanjutnya. Sebagai bukti berjalannya proses ekstraksi fitur secara komputasional, peneliti menyajikan representasi keluaran model dari dua sampel produk pertama pada dataset, sebagaimana ditunjukkan pada Tabel 4.8.

Tabel 4.8 Hasil Implementasi Ekstraksi Fitur Citra menggunakan ResNet50

Nama Produk	Path Gambar	Dimensi Vektor	Sampel Nilai Vektor (6 Nilai Pertama)
No7 Hydra Luminous Aqua Release Skin Perfector Tinted Moisturiser, Medium, 1 fl oz/30 mL		2048	[0.0, 0.62625843, 0.98614585, 0.1967417, 0.0276369, 0.31095248]

Tower 28 SOS Daily Rescue Facial Spray, 4 fl oz/120 mL		2048	[0.0, 0.25968555, 0.19989327, 0.0, 1.2887335, 0.04881386]
--	---	------	--

Berdasarkan Tabel 4.8, peneliti mendapati bahwa model ResNet50 telah berhasil mengekstraksi informasi visual dari dua sampel produk yang memiliki karakteristik fisik sangat berbeda. Sampel pertama (*No7 Hydra Luminous*) merupakan produk dengan kemasan berbentuk *tube* yang didominasi warna biru dan krem, sedangkan sampel kedua (*Tower 28 SOS*) merupakan produk dengan kemasan botol *spray* berwarna oranye. Meskipun kedua citra tersebut memiliki struktur bentuk dan warna dasar yang jauh berbeda, model secara konsisten mampu memproyeksikannya ke dalam ruang vektor berdimensi seragam, yaitu 2048.

Kolom sampel nilai vektor memperlihatkan deretan angka desimal yang merupakan bobot numerik dari karakteristik visual yang berhasil ditangkap oleh filter konvolusi pada jaringan saraf tiruan. Perbedaan komposisi angka pada kedua baris tersebut merepresentasikan perbedaan ciri khas visual antar kemasan produk. Selain itu, kemunculan nilai 0.0 pada beberapa elemen vektor merupakan hal yang normal dalam arsitektur yang menggunakan fungsi aktivasi *Rectified Linear Unit* (ReLU), yang mengindikasikan bahwa fitur spesifik pada node (*neuron*) tersebut tidak teraktivasi oleh pola gambar yang sedang diproses.

Keseragaman ukuran dimensi vektor ini membuktikan bahwa tahapan ekstraksi fitur citra telah dieksekusi dengan baik dan terstandarisasi. Representasi numerik default 2048 ini menjadi parameter yang sangat ideal dan siap untuk digabungkan (*feature fusion*) dengan matriks teks TF-IDF sebelum akhirnya dihitung derajat kedekatannya menggunakan metode komputasi *Cosine Similarity*.

4.3.2 TF-IDF

Ekstraksi fitur tekstual pada penelitian ini diimplementasikan menggunakan algoritma *Term Frequency-Inverse Document Frequency* (TF-IDF) terhadap data komposisi bahan produk yang telah dibersihkan pada atribut `clean_ingredients`. Alur kerja implementasi ini diawali dengan pengambilan data teks berformat *string*, yang kemudian diproses melalui tahapan tokenisasi untuk memecah untaian kalimat komposisi menjadi entitas kata dasar tunggal (*term*). Untuk memastikan akurasi pembobotan, peneliti menggunakan seluruh populasi dataset dalam proses *fitting* model sehingga distribusi nilai IDF yang dihasilkan benar-benar merepresentasikan rasio kemunculan kata pada seluruh dokumen *skincare* yang diteliti. Pada tahap pembentukan vektor fitur berdasarkan kosakata (*vocabulary*), peneliti menetapkan konfigurasi batas maksimal fitur (`max_features`) sebanyak 5.000 kata teratas. Pembatasan ini dilakukan dengan pertimbangan untuk menyaring *noise* dengan mengeliminasi kata atau istilah bahan kimia langka yang frekuensi kemunculannya sangat rendah, serta untuk menjaga efisiensi beban komputasi agar dimensi teks tetap proporsional saat digabungkan dengan matriks citra ResNet50 (2048 dimensi). Penetapan ini menghasilkan representasi akhir berupa vektor numerik berdimensi 5000 untuk setiap entitas produk di dalam sistem.

Secara komputasional, algoritma ini bekerja melalui dua tahap perhitungan utama. Tahap pertama adalah perhitungan *Term Frequency* (TF), yaitu kalkulasi jumlah kemunculan sebuah kata secara spesifik di dalam satu dokumen produk tertentu. Tahap kedua adalah perhitungan *Inverse Document Frequency* (IDF), yang diformulasikan menggunakan operasi logaritma dari pembagian antara total keseluruhan dokumen produk dengan jumlah dokumen yang mengandung kata tersebut. Bobot akhir dari suatu kata (*term*) didapatkan melalui perkalian antara kedua nilai tersebut ($TF \times IDF$) [17]. Melalui mekanisme matematis ini, sistem secara otomatis memberikan penalti bobot yang kecil pada kata yang sangat sering muncul namun bersifat umum pada keseluruhan *dataset* (seperti kata *water* atau *aqua*). Sebaliknya, kata aktif yang unik dan spesifik pada produk tertentu akan memperoleh bobot yang jauh lebih besar.

Untuk mendemonstrasikan hasil dari proses ekstraksi komputasional ini, peneliti mengambil satu sampel produk teratas pada dataset, yaitu produk "*No7 Hydra Luminous Aqua Release Skin Perfector Tinted Moisturiser*". Sebagai basis bahan analisis observasi, peneliti mengambil 10 kata pertama dari atribut komposisi bahan produk tersebut yang meliputi: *propylene*, *glycol*, *alcohol*, *denat*, *anhydroxylitol*, *aqua*, *water*, *butylene*, *glycol*, dan *caprylyl*. Rincian hasil komputasi bobot untuk kesepuluh *token* tersebut ditunjukkan pada Tabel 4.9.

Tabel 4.9 Hasil Ekstraksi Bobot TF-IDF pada 10 Kata Pertama Ingredients

Kata (Term)	Bobot TF-IDF
propylene	0.1091
glycol	0.1048
alcohol	0.0611
denat	0.1363
anhydroxylitol	0.1796
aqua	0.0802
water	0.0603
butylene	0.0716
glycol	0.1048
caprylyl	0.0759

Berdasarkan hasil pembobotan pada Tabel 4.9, dapat diobservasi bahwa model TF-IDF telah berhasil mengonversi teks bahan kimia ke dalam representasi bobot numerik desimal yang bervariasi bergantung pada spesifikasinya. Peneliti

perlu menggarisbawahi bahwa karena adanya penerapan batas *max_features* sebesar 5000, tidak semua kata dari keseluruhan populasi korpus akan memiliki bobot. Apabila terdapat istilah bahan kimia yang frekuensi kemunculannya terlalu rendah sehingga tereliminasi dari batas 5.000 fitur tersebut, maka algoritma akan mengembalikan nilai bobot sebesar 0.0000 untuk kata tersebut. Secara akumulatif, hasil implementasi ini mengonfirmasi bahwa data teks telah sukses ditransformasikan menjadi susunan vektor numerik final berdimensi konstan 5000. Ruang vektor inilah yang pada tahap komputasi selanjutnya akan digabungkan (*fusion*) dengan fitur citra untuk memfasilitasi pengukuran derajat kemiripan antar produk menggunakan metrik *Cosine Similarity*.

4.4 Cosine Similarity

Setelah proses ekstraksi fitur multimodal selesai, tahapan selanjutnya dalam implementasi sistem ini adalah menghitung tingkat kemiripan antar produk menggunakan metrik komputasi *Cosine Similarity* [22]. Pada penelitian ini, peneliti melakukan komputasi jarak kemiripan secara independen terhadap dua jenis representasi fitur yang telah dibentuk, yakni fitur citra dengan dimensi 2048 dan fitur tekstual dengan dimensi 5000. Alur kerja implementasi ini diawali dengan tahap mengambil vektor fitur dari satu produk yang ditunjuk sebagai produk target. Setelah itu, sistem mengambil vektor fitur dari produk-produk pembanding yang ada di dalam dataset. Vektor target dan vektor pembanding tersebut kemudian dievaluasi untuk menghitung nilai kemiripan pada fitur citra dan nilai kemiripan pada fitur teks. Nilai keluaran dari perhitungan metrik *Cosine Similarity* ini selalu berada pada rentang 0.0000 hingga 1.0000, di mana nilai 0 merepresentasikan ketiadaan kemiripan sama sekali, sedangkan nilai 1 menandakan bahwa kedua produk identik secara absolut.

Menyadari bahwa rekomendasi produk skincare membutuhkan akurasi tinjauan fisik dan komposisi bahan, peneliti menerapkan pendekatan fusi (hybrid) untuk menentukan keputusan rekomendasi. Agar penilaian sistem berjalan objektif, peneliti menetapkan rasio pembobotan hibrida yang tidak setara (*unequal weighting*), yakni sebesar 80% untuk fitur tekstual dan 20% untuk fitur visual.

Penetapan bobot yang berbeda ini dilandaskan pada penelitian Fitriyeh dkk. (2024), yang menyatakan bahwa penggabungan dua pendekatan fitur dalam sistem hibrida seharusnya menggunakan pembobotan yang tidak setara, karena masing-masing metode memiliki performa dan tingkat pengaruh yang berbeda terhadap hasil akhir rekomendasi [26]. Hal ini turut didukung oleh penelitian Salam dkk. (2024), yang menegaskan bahwa bobot yang lebih tinggi harus diberikan pada metode yang paling kuat mencerminkan preferensi utama pengguna, sementara metode yang lebih khusus atau bersifat pendukung cukup diberikan bobot yang lebih rendah²⁵. Dalam konteks produk skincare, komposisi bahan kimia (teks) merupakan faktor krusial yang menentukan kecocokan produk sehingga diberikan porsi dominan (80%), sedangkan kemasan fisik (visual) bertindak sebagai identitas pendukung (20%).

Adapun penentuan angka pasti rasio 80:20 ini didapatkan melalui proses evaluasi empiris atau penyesuaian parameter (parameter fitting). Sebagaimana yang diimplementasikan dalam skenario pengujian sistem hibrida oleh Fitriyeh dkk. (2024), penetapan nilai parameter bobot dilakukan dengan mengevaluasi beberapa variasi nilai bobot melalui uji coba untuk menemukan kombinasi yang menghasilkan akurasi tertinggi bagi sistem [26]. Oleh karena itu, rasio 80:20 pada penelitian ini merupakan hasil optimasi empiris yang terbukti paling mampu meminimalkan bias serta memberikan hasil pencocokan produk alternatif terbaik. Sebagai bukti dari proses komputasi ini, peneliti menetapkan satu produk pada dataset, yaitu produk "No7 Hydra Luminous Aqua Release Skin Perfector Tinted Moisturiser, Medium, 1 fl oz/30 mL", sebagai produk target. Sistem kemudian membandingkan produk target tersebut dengan tiga buah produk lainnya sebagai pembanding. Rincian hasil komputasi beserta perbandingan visual kemasan dan komposisi bahan dari simulasi tersebut disajikan pada Tabel 4.10.

Tabel 4.10 Hasil Komputasi *Cosine Similarity* dan Pembobotan *Hybrid*

Gambar Produk	Produk Pembanding	Bahan Kimia (Ingredients)	Skor Visual	Skor Teks	Skor Hybrid
	Tower 28 SOS Daily Rescue Facial Spray, 4 fl oz/120 mL	Hypochlorous Acid, Sodium Chloride, Water	0.655	0.011	0.3333
	Clinique Takes the Day Off Cleansing Oil, 6.7 fl oz/200 mL	Bht, Caprylyl Glycol, Cetyl Ethylhexanoate, Glycerin, Glyceryl Laurate, Peg-12 Diisostearate, Peg-20 Glyceryl Triisostearate, Peg-8 Diisostearate, Polybutene, Ppg-15 Stearyl Ether, Tocopheryl Acetate, Triethylhexanoin, Water\Aqua\Eau	0.634	0.0375	0.336
	Necessaire The Body Lotion, Fragrance Free, 15.2 fl oz/450 mL	Aqua/Water/Eau, Caprylhydroxamic Acid, Caprylic/Capric Triglyceride, Caprylyl Glycol, Caryodendron Orinocense Seed Oil, Cetearyl Alcohol, Cetearyl Olivate, Dicaprylyl Carbonate, Glycerin, Glyceryl Stearate, Limnanthes Alba (Meadowfoam) Seed Oil, Linoleic Acid, Linolenic Acid, Niacinamide, Oleic Acid, Palmitic Acid,	0.590	0.0303	0.3105

		Palmitoyl Dipeptide-5 Diaminobutyroyl Hydroxythreonine, Palmitoyl Dipeptide-5 Diaminohydroxybutyrate, Palmitoyl Hexapeptide-12, Palmitoyl Tetrapeptide-7, Palmitoyl Tripeptide-1, Polyacrylate Crosspolymer-6, Propanediol, Sclerocarya Birrea Seed Oil, Shea Butter Glycerides, Simmondsia Chinensis (Jojoba) Seed Oil, Stearic Acid, T-Butyl Alcohol, Tocopherol, Xanthan Gum			
--	--	---	--	--	--

Berdasarkan hasil pemrosesan data pada Tabel 4.10, skor *hybrid* yang berada di kolom terakhir digunakan sebagai dasar komputasi sistem dalam menentukan tingkat kemiripan produk secara keseluruhan. Penilaian ini berlandaskan pada prinsip dasar pemodelan rekomendasi, di mana semakin tinggi nilai skor *hybrid* yang dihasilkan, maka semakin tinggi pula tingkat kemiripan antara produk pembanding dengan produk target. Hasil perhitungan ini menegaskan bahwa pendekatan *hybrid* mampu menggabungkan informasi visual dan tekstual secara seimbang. Sebagai contoh, meskipun produk pertama (Tower 28) memiliki kemiripan visual tertinggi (0.6557), namun skor akhir tertingginya dimenangkan oleh produk kedua (Clinique) dengan nilai 0.3360 karena produk kedua memiliki tingkat kemiripan teks yang lebih baik, sehingga mendongkrak akumulasi skor hibridanya.

4.5 Sistem Rekomendasi

Tahapan operasional utama dari sistem yang dikembangkan pada penelitian ini adalah proses pembentukan rekomendasi produk. Alur kerja sistem secara keseluruhan diawali dengan interaksi pengguna melalui penginputan kata kunci (*keyword*) pencarian. Kata kunci tersebut kemudian diproses oleh sistem untuk melakukan pencarian produk di dalam korpus dataset yang memiliki relevansi penamaan. Dari daftar hasil pencarian awal tersebut, sistem secara komputasional akan mengekstraksi dan menetapkan produk yang berada pada urutan pertama sebagai produk acuan atau produk target. Berdasarkan hasil eksekusi program, saat peneliti memasukkan kata kunci pencarian "*Serum*", sistem menemukan 607 produk terkait dan secara otomatis menetapkan produk "*The Ordinary A High-Strength Serum, Alpha Arbutin 2% + Ha, 1 fl oz/30 mL*" sebagai produk acuan. Produk ini dieksekusi dan dijadikan referensi utama dalam proses perbandingan karena kemunculannya di urutan pertama mengindikasikan tingkat relevansi *string* tertinggi terhadap intensi pencarian pengguna. Agar produk acuan tersebut dapat dianalisis lebih lanjut, sistem melakukan pemanggilan representasi matriksnya. Representasi ini mencakup fitur citra (hasil ekstraksi model ResNet50 berupa matriks vektor berdimensi 2048) serta fitur teks komposisi bahan (hasil model TF-IDF berupa matriks vektor berdimensi 5000). Kedua set fitur tersebut merupakan larik vektor numerik murni yang secara mutlak digunakan sebagai fondasi bagi sistem dalam mengkalkulasi skala kemiripan antara produk acuan dengan entitas produk lainnya di dalam dataset.

Setelah representasi vektor numerik produk acuan didefinisikan, sistem melanjutkan proses evaluasi komparatif secara menyeluruh. Sistem membandingkan vektor produk acuan tersebut dengan vektor seluruh produk lain dalam dataset secara iteratif. Perhitungan jarak kedekatan ini dilakukan melalui dua jalur, yaitu komputasi *similarity* pada matriks citra dan komputasi *similarity* pada matriks teks. Hasil kuantitatif dari kedua perhitungan independen tersebut kemudian digabungkan menggunakan pendekatan hibrida (*hybrid*). Peneliti merancang formulasi sistem untuk mengekstraksi skor akhir (*similarity score*)

dengan rasio pembobotan gabungan sebesar 20% untuk *similarity* citra dan 80% untuk *similarity* teks. Berdasarkan akumulasi skor akhir tersebut, sistem mengeksekusi proses perankingan (*ranking*) dengan mengurutkan produk dari titik skor tertinggi hingga terendah. Pada tahap luaran akhir, sistem memfilter data dan mengekstraksi lima produk teratas (*Top-5*) untuk direkomendasikan kepada pengguna. Bukti tangkapan layar (*screenshot*) dari hasil eksekusi program untuk proses pemeringkatan ini dapat dilihat pada Gambar 4.1, sedangkan rincian nilai komputasi antarkomponennya didokumentasikan pada Tabel 4.11.

Gambar 4.1 Hasil *screenshot Top-5* Rekomendasi Produk *Skincare*

★ REKOMENDASI UNTUK: The Ordinary A High-Strength Serum, Alpha Arbutin 2% + Ha, 1 fl oz/30 mL					
	product_name	category	product_url	image_url	Score
416	M-61 Vitablast C Serum 2.0	Moisturizing Serums	Link	Link	0.604100
4410	The Ordinary Peeling Solution AHA 30% + BHA 2%, 30 ml	Acids & Peels	Link	Link	0.589700
982	The Ordinary Balancing & Clarifying Serum, 1 fl oz/30 mL	Serums	Link	Link	0.585000
453	The Ordinary Ascorbyl Glucoside Solution 12% 30ml	Skin Treatments	Link	Link	0.576900
1698	Good Molecules Hyaluronic Acid Serum, 2.5 fl oz/75 mL	Serums	Link	Link	0.567300

Tabel 4.11 Hasil *Top-5* Rekomendasi Produk *Skincare* (Kueri: "Serum")

Nama Produk	Kategori	Skor Similarity
M-61 Vitablast C Serum 2.0	Moisturizing Serums	0.6041
The Ordinary Peeling Solution AHA 30% + BHA 2%...	Acids & Peels	0.5897
The Ordinary Balancing & Clarifying Serum, 1 f...	Serums	0.5850
The Ordinary Ascorbyl Glucoside Solution 12% 30ml	Skin Treatments	0.5769

Good Molecules Hyaluronic Acid Serum, 2.5 fl o...	Serums	0.5673
---	--------	--------

Berdasarkan output komputasi pada Tabel 4.11, dapat dianalisis bahwa produk yang menempati peringkat teratas (*M-61 Vitablast C Serum 2.0*) dengan skor tertinggi sebesar 0.6041 merupakan produk yang dikomputasi paling mirip dengan produk acuan ("*The Ordinary Alpha Arbutin 2% + HA*"). Nilai desimal pada kolom *Skor Similarity* tersebut menunjukkan derajat tingkat kedekatan karakteristik fisik dan kimiawi antar produk. Hasil implementasi ini membuktikan bahwa sistem yang dibangun mampu beroperasi dengan baik dan memberikan rekomendasi yang sangat relevan. Hal ini terlihat dari masuknya beberapa produk lain dari *brand* yang sama ("*The Ordinary*") pada urutan kedua hingga keempat, yang secara logis memiliki kemiripan desain kemasan botol pipet (*visual*) dan kemiripan penamaan bahan aktif penyusunnya (*tekstual*). Pencapaian ini menegaskan bahwa kombinasi fitur visual citra dan fitur tekstual komposisi bahan berkontribusi secara seimbang dan efektif dalam membangun sebuah sistem rekomendasi yang komprehensif.

4.6 Evaluasi

Tahapan krusial setelah sistem rekomendasi berhasil diimplementasikan adalah melakukan pengujian dan evaluasi kinerja. Tujuan utama dari evaluasi ini adalah untuk mengukur tingkat keandalan, akurasi, dan kualitas distribusi data pada model *Hybrid Content-Based Filtering* yang telah dibangun. Proses evaluasi ini secara komprehensif menguji representasi ruang fitur hibrida, yang merupakan gabungan matriks numerik dari ekstraksi citra (ResNet50) dan ekstraksi teks (TF-IDF).

Dalam penelitian ini, peneliti menggunakan tiga instrumen pengujian utama yang diimplementasikan secara terprogram. Ketiga instrumen tersebut adalah *Precision@5* untuk mengukur akurasi relevansi dari daftar rekomendasi teratas, *Silhouette Score* untuk mengukur kualitas pemisahan klaster produk di dalam ruang vektor, serta *t-SNE* untuk memvisualisasikan persebaran data secara dua dimensi.

Seluruh tahapan komputasi pada evaluasi ini difokuskan pada pengujian hasil gabungan (hibrida) dengan rasio 20% fitur citra dan 80% fitur teks.

4.6.1 Precision@5

Metrik evaluasi pertama yang diimplementasikan oleh peneliti adalah Precision@5. Pengujian ini bertujuan untuk mengukur persentase kebenaran kategori dari lima produk teratas yang direkomendasikan oleh sistem, dibandingkan dengan kategori produk acuan secara faktual (ground truth).

Alur kerja implementasi pengujian ini diawali dengan tahapan pengambilan sampel data produk secara komputasional. Untuk setiap produk yang dijadikan sampel acuan, sistem mengeksekusi perhitungan Cosine Similarity secara paralel pada fitur citra dan fitur teks. Kedua skor kemiripan independen tersebut kemudian diagregasi untuk membentuk skor hibrida akhir. Berdasarkan akumulasi skor akhir tersebut, sistem mengekstraksi dan mengambil lima produk pembanding dengan nilai tertinggi (Top-5). Selanjutnya, peneliti merancang sistem agar secara otomatis membandingkan kecocokan label kategori dari kelima produk rekomendasi tersebut dengan label kategori dari produk sampel. Rasio keberhasilan dari produk yang memiliki kategori relevan kemudian dikalkulasikan untuk mendapatkan nilai akurasi presisi akhir. Pada iterasi awal (baseline), sistem hanya mendapatkan presisi yang rendah sebesar 33.60%. Sesuai dengan alur penelitian, peneliti kemudian melakukan siklus iterasi (tahap *improved*) untuk mengoptimalkan pemfilteran fitur hibrida. Hasil dari iterasi tersebut berhasil mendongkrak performa sistem secara signifikan, di mana rincian hasil keluaran komputasi Precision@5 terbaru dapat dilihat pada Tabel 4.12.

Tabel 4.12 Hasil Pengujian Precision@5

Metrik	Nilai
Precision@5	0.9860
Persentase	98.60%

Hasil pengujian performa sistem menggunakan metrik Precision@5 mencatatkan tingkat akurasi sebesar 98.60%. Nilai persentase ini membuktikan bahwa proporsi produk relevan yang direkomendasikan oleh sistem jauh lebih besar dibandingkan dengan total rekomendasi yang diberikan. Tingginya nilai metrik ini sejalan dengan landasan teori pada penelitian Salam dkk. (2024), yang menegaskan bahwa nilai Precision yang tinggi secara langsung menandakan bahwa daftar rekomendasi yang dihasilkan oleh model sudah sangat sesuai dengan preferensi dan kebutuhan sebenarnya dari pengguna [25]. Sebagai perbandingan empiris pada literatur tersebut, capaian presisi sebesar 85% sudah dikategorikan sebagai nilai yang tinggi dan mampu menciptakan keseimbangan rekomendasi yang optimal [25]. Oleh karena itu, perolehan angka 98.60% pada pengujian ini menegaskan bahwa sistem Hybrid Content-Based Filtering yang dibangun memiliki tingkat keandalan yang sangat presisi, di mana sistem hampir tidak pernah melakukan kesalahan dalam menyajikan alternatif produk skincare yang relevan bagi target pengguna.

4.6.2 Silhouette Score

Tahapan evaluasi selanjutnya adalah kalkulasi Silhouette Score. Metrik ini diimplementasikan untuk menganalisis secara matematis seberapa baik kohesi (kerekatan) antara produk-produk di dalam sebuah kategori yang sama, dibandingkan dengan separasi (jarak) produk tersebut terhadap kategori yang berbeda.

Secara operasional, alur evaluasi ini dimulai ketika peneliti menggabungkan matriks vektor fitur citra dan matriks vektor fitur teks secara horizontal untuk membentuk satu ruang multidimensi hibrida yang utuh. Dalam proses ini, label kategori asli dari setiap entitas produk digunakan sebagai penanda kluster target. Komputer kemudian mengkalkulasi jarak rata-rata antar produk di dalam kluster yang sama (*intra-cluster distance*) dan jarak rata-rata sebuah produk dengan kluster terdekat lainnya (*inter-cluster distance*). Hasil perbandingan dari kedua ukuran metrik jarak tersebut menghasilkan sebuah nilai keluaran skalar yang terdokumentasi pada Tabel 4.13.

Tabel 4.13 Hasil Pengujian Silhouette Score


Metrik	Nilai
Silhouette Score	-0.2101

Berdasarkan hasil pemrosesan pada Tabel 4.13, sistem mengembalikan *Silhouette Score* dengan nilai negatif sebesar -0.2024. Nilai tersebut menginterpretasikan bahwa jarak batas antar kategori produk *skincare* di dalam sebaran dataset sangat kabur dan saling tumpang tindih (*overlap*). Fenomena tumpang tindih data ini sejalan dengan karakteristik dataset *e-commerce* pada umumnya, di mana batas antar kategori produk sering kali tidak tegas akibat kemiripan atribut yang tinggi. Secara empiris, banyak produk perawatan kulit dari kategori berbeda (misalnya *Lotion*, *Cream*, atau *Serum*) terdeteksi mirip karena menggunakan komposisi bahan pelarut dasar yang sama (seperti *water* atau *glycerin*), serta dikemas menggunakan standar wujud botol fisik yang serupa [3][6].

4.6.3 Visualisasi t-SNE

Untuk memvalidasi temuan dari pengujian Silhouette Score secara komprehensif, peneliti melakukan pendekatan analisis kualitatif melalui representasi visual *t-Distributed Stochastic Neighbor Embedding (t-SNE)*. Alur komputasi visualisasi ini dimulai dengan menerapkan teknik perantara *Principal Component Analysis (PCA)* untuk mereduksi besaran dimensi data hibrida awal guna menekan beban komputasi perangkat keras. Setelah dimensi spasial berhasil diringkas oleh model PCA, algoritma t-SNE memproyeksikan seluruh vektor fitur produk tersebut ke dalam representasi ruang dua dimensi (Sumbu X dan Sumbu Y).

Data yang telah berbentuk koordinat titik tersebut kemudian diplot ke dalam bentuk diagram pencar (*scatter plot*). Hasil visualisasi pemetaan persebaran data tersebut dapat dilihat pada Gambar 4.2.



Gambar 4.2 Visualisasi Scatter Plot t-SNE Berdasarkan Fitur Hibrida

Berdasarkan Gambar 4.2, setiap titik (*node*) yang tercetak pada diagram merepresentasikan satu entitas produk perawatan kulit. Identitas warna pada titik-titik tersebut disandikan berdasarkan lima kategori produk utama, yaitu warna biru untuk Lotions, oranye untuk Creams, hijau untuk Serums, merah untuk Facial Masks, dan ungu untuk Lip Balms, Gels, Moisturizers & Oils.

Hasil proyeksi dari eksekusi t-SNE ini memperlihatkan bahwa sistem berhasil mengidentifikasi pola dan menciptakan beberapa area pengelompokan (*clustering*), seperti dominasi titik oranye (*Creams*) di sisi kiri, titik hijau (*Serums*) di area tengah hingga atas, serta titik merah (*Facial Masks*) di area bawah. Akan tetapi, secara keseluruhan, mayoritas sebaran kumpulan titik antar warna terlihat saling membaur secara intens di berbagai titik perpotongan. Visualisasi ini secara valid mengonfirmasi interpretasi matematis dari Silhouette Score sebelumnya, yang mengindikasikan adanya tingkat tumpang tindih (*overlap*) yang tinggi. Tingginya tingkat pembauran (*clustering overlap*) ini merupakan hal yang wajar dalam segmentasi produk kecantikan komersial, mengingat tingginya kemiripan intrinsik pada desain wujud fisik kemasan serta kompleksitas penggunaan zat kimia (*ingredients*) dasar yang serupa lintas kategori [23].

4.6.4 Kesimpulan Evaluasi

Berdasarkan rangkaian implementasi dan komputasi pengujian yang telah dipaparkan, dapat disimpulkan bahwa sistem rekomendasi hibrida berbasis ResNet-50 dan TF-IDF telah berhasil beroperasi secara menyeluruh. Sistem mampu mengekstraksi nilai kemiripan fitur dari data citra dan teks secara konsisten meskipun memproses data multidimensi yang kompleks. Kondisi homogenitas data terlihat dari perolehan nilai Silhouette Score sebesar -0,2024 serta visualisasi t-SNE yang menunjukkan adanya tumpang tindih antar kelompok data. Hasil tersebut mengindikasikan bahwa karakteristik produk dalam dataset memiliki tingkat kemiripan yang cukup tinggi sehingga batas antar kelompok produk tidak terbentuk secara jelas.

Meskipun demikian, sistem menunjukkan performa rekomendasi yang sangat baik dengan memperoleh nilai Precision@5 sebesar 98,60%. Nilai tersebut menunjukkan bahwa sebagian besar produk yang direkomendasikan memiliki relevansi yang tinggi terhadap produk acuan yang digunakan dalam pencarian. Dengan demikian, sistem telah berhasil mencapai tujuan penelitian dalam menghasilkan rekomendasi produk skincare yang relevan berdasarkan kombinasi fitur visual dan tekstual.

Berdasarkan hasil evaluasi tersebut, sistem dinilai layak untuk diimplementasikan dalam bentuk prototype aplikasi dan dapat dilanjutkan ke tahap deployment. Tahap ini dilakukan untuk mendemonstrasikan bagaimana sistem rekomendasi dapat digunakan oleh pengguna melalui antarmuka web yang telah dikembangkan.

4.7 Deployment

Tahapan akhir dari penelitian ini adalah tahap implementasi dan *deployment* sistem, di mana sistem rekomendasi *skincare* telah berhasil direalisasikan secara fungsional. prototype ini dibangun dan dikembangkan dalam bentuk aplikasi berbasis web menggunakan antarmuka dari *framework* Streamlit. Pemanfaatan *framework* tersebut dirancang oleh peneliti agar sistem dapat beroperasi secara

interaktif dan mudah diakses oleh pengguna akhir. Adapun tujuan utama dari tahapan implementasi ini adalah untuk menguji serta memvalidasi kinerja algoritma sistem rekomendasi secara langsung dalam kondisi penggunaan yang nyata.

Saat aplikasi web pertama kali diakses, pengguna akan dihadapkan pada tampilan awal antarmuka yang memuat judul utama "Temukan Skincare yang Cocok untukmu" serta sebuah kolom input *keyword* yang difungsikan untuk pencarian produk awal.

Temukan Skincare yang Cocok untukmu ✨

Cari produk favoritmu, lalu temukan alternatif lain dengan kandungan yang mirip dan cocok untuk kebutuhan kulitmu.

1. Cari Brand / Produk

Ketik nama produk...

Misal: The Ordinary, Laneige...

Gambar 4.3 Tampilan Halaman Utama dan Kolom Pencarian

Proses interaksi dimulai ketika pengguna memasukkan kata kunci tertentu, sebagai contoh menggunakan kata kunci "serum". Setelah kata kunci dimasukkan, sistem secara otomatis memindai dataset dan menampilkan daftar hasil pencarian produk yang relevan. Selanjutnya, antarmuka menyediakan elemen *dropdown* yang berfungsi bagi pengguna untuk menyeleksi dan memilih salah satu produk dari daftar hasil pencarian tersebut. Produk yang telah dipilih oleh pengguna kemudian ditampilkan secara lengkap pada layar, mencakup informasi visual berupa gambar produk, serta rincian tekstual yang meliputi nama produk, *brand*, kategori, dan tautan pendukung. Dalam arsitektur sistem ini, peneliti menetapkan bahwa produk yang divisualisasikan tersebut bertindak sebagai produk acuan atau produk target yang menjadi basis utama dalam komputasi sistem rekomendasi.

Temukan Skincare yang Cocok untukmu ✨

Cari produk favoritmu, lalu temukan alternatif lain dengan kandungan yang mirip dan cocok untuk kebutuhan kulitmu.

1. Cari Brand / Produk

Ketik nama produk...

2. Pilih Varian

Ditemukan 607 hasil pencarian:

The Ordinary A High-Strength Serum, Alpha Arbutin 2% + Ha, 1 fl oz/30 mL



PRODUK YANG ANDA CARI

The Ordinary A High-Strength Serum, Alpha Arbutin 2% + Ha, 1 fl oz/30 mL


Brand: The Ordinary | Kategori: Serums

[Beli / Cek Harga](#)

[Lihat Detail Kandungan \(Ingredients\)](#)

Gambar 4.4 Tampilan Pemilihan Produk Acuan

Interaksi berlanjut ketika pengguna menekan tombol "Temukan Produk Serupa", yang mana aksi ini memicu sistem di latar belakang untuk memulai proses kalkulasi tingkat kemiripan. Sistem mengeksekusi perhitungan *similarity* pada fitur citra menggunakan model ResNet50 dan secara paralel menghitung *similarity* pada fitur teks menggunakan TF-IDF. Kedua skor independen tersebut kemudian digabungkan melalui pendekatan *hybrid*, di mana peneliti mengonfigurasi pembobotan skor sebesar 20% untuk citra dan 80% untuk teks. Berdasarkan akumulasi skor gabungan tersebut, sistem melakukan proses *ranking* secara menurun untuk mencari produk dengan nilai *similarity* tertinggi. Sebagai hasil akhir dari keseluruhan proses komputasi, antarmuka aplikasi menyajikan daftar *Top 5* rekomendasi produk. Representasi luaran ini ditampilkan secara terstruktur dalam bentuk kartu (*card*) informasi, di mana masing-masing kartu memuat gambar produk, persentase kemiripan (*match*), nama *brand*, nama produk yang direkomendasikan, serta tombol interaktif untuk melihat detail produk lebih lanjut.



Gambar 4.5 Tampilan Antarmuka Hasil Rekomendasi Produk

Berdasarkan keseluruhan proses yang telah dipaparkan, sistem rekomendasi berhasil diimplementasikan ke dalam bentuk aplikasi web berbasis Streamlit. Antarmuka yang dikembangkan memberikan kemudahan bagi pengguna melakukan pencarian produk, memilih produk acuan, serta memperoleh rekomendasi produk serupa secara interaktif. Implementasi ini menunjukkan bahwa algoritma hybrid yang menggabungkan fitur visual ResNet-50 dan fitur tekstual TF-IDF dapat diintegrasikan dengan baik ke dalam sebuah aplikasi fungsional dan digunakan untuk mendemonstrasikan proses rekomendasi produk skincare secara langsung.

Peneliti merilis prototipe antarmuka sistem yang dibangun berbasis framework Streamlit. Karena prototipe ini beroperasi sebagai simulasi layanan, konsumen awam menjadi target pengguna utama untuk mengeksplorasi referensi produk alternatif secara mandiri. Selain itu, praktisi kecantikan maupun dokter kulit berpotensi memanfaatkan sistem ini sebagai alat bantu referensi tambahan dalam mengidentifikasi produk dengan kandungan bahan yang serupa atau sebagai alternatif bagi pengguna dengan kebutuhan tertentu.

Meskipun prototipe yang dikembangkan masih beroperasi secara terisolasi dan belum terintegrasi dengan layanan transaksi maupun data pengguna secara langsung, konsep implementasinya memiliki potensi untuk diterapkan pada berbagai sektor industri. Perusahaan e-commerce dapat mengintegrasikan sistem rekomendasi ini ke dalam katalog produk digital, toko kosmetik dapat memanfaatkannya pada perangkat kiosk untuk membantu pelanggan menemukan

produk alternatif, sedangkan klinik perawatan kulit dapat menggunakannya sebagai sarana pendukung pencarian referensi produk bagi pasien. Potensi tersebut menunjukkan bahwa sistem yang dibangun tidak hanya berfungsi sebagai prototipe penelitian, tetapi juga memiliki peluang untuk dikembangkan lebih lanjut pada lingkungan operasional yang lebih luas.

BAB V PENUTUP

5.1 Kesimpulan

Berdasarkan hasil perancangan, implementasi, dan pengujian sistem yang telah diuraikan pada bab-bab sebelumnya, maka dapat ditarik kesimpulan yang menjawab rumusan masalah pada penelitian ini sebagai berikut:

1. Implementasi metode *Hybrid Content-Based Filtering* pada sistem rekomendasi *skincare* telah berhasil diselesaikan secara berurutan. Tahap pengumpulan data sukses mengakuisisi 4.800 sampel data dari *dataset* SkinSafe. Tahap *preprocessing* berhasil menormalisasi citra menjadi 224x224 piksel dan membersihkan derau teks. Tahap ekstraksi menggunakan ResNet-50 berhasil menghasilkan matriks citra berdimensi 2048, sedangkan TF-IDF sukses menghasilkan matriks teks berdimensi 5000. Kedua matriks digabungkan dan dihitung kemiripannya pada tahap *Cosine Similarity* dengan rasio 20% visual dan 80% tekstual. Rangkaian ini diakhiri dengan proses *deployment* yang berhasil menyajikan 5 rekomendasi produk teratas (*Top-5*) pada antarmuka web Streamlit.
2. Hasil evaluasi kinerja sistem menunjukkan bahwa akurasi rekomendasi kategori produk tergolong sangat tinggi dan presisi, dibuktikan dengan capaian metrik *Precision@5* yang mencapai 98,60%. Meskipun kualitas pemisahan jarak antar-klaster data berdimensi tinggi kurang optimal, ditunjukkan oleh nilai metrik *Silhouette Score* yang negatif sebesar -0,2024 serta visualisasi pemetaan *t-SNE* yang saling membaaur akibat karakteristik intrinsik komposisi bahan dasar kosmetik yang homogen, hal ini tidak mengurangi relevansi hasil rekomendasi akhir sistem. Oleh karena itu, hasil pengujian ini dinyatakan telah memenuhi kriteria keberhasilan pengenalan konten, sehingga pemodelan sistem ini valid dan layak untuk langsung dilanjutkan ke tahapan *deployment* tanpa memerlukan perbaikan atau perombakan pada arsitektur algoritma utama.

5.2 Saran

Terdapat beberapa hal yang disarankan untuk pengembangan dan penyempurnaan sistem rekomendasi ini di masa mendatang, antara lain:

1. Peningkatan Kapasitas Komputasi dan Skala Data: Pada penelitian ini, penerapan teknik *data sampling* membatasi penggunaan data hanya pada sekitar 4.800 sampel dari total 50.000 populasi produk guna menjaga efisiensi beban komputasi. Penelitian selanjutnya disarankan untuk menggunakan dukungan spesifikasi perangkat keras dan infrastruktur komputasi *cloud* yang lebih tinggi agar dapat memproses korpus data secara utuh, sehingga hasil rekomendasi yang diberikan bisa jauh lebih bervariasi.
2. Penerapan Pembobotan Hibrida yang Dinamis: Mengingat formulasi hibrida yang digunakan saat ini mengandalkan rasio statis yang tidak dapat diubah oleh pengguna, pengembangan aplikasi ke depan dapat menambahkan fitur pembobotan dinamis pada antarmuka. Fitur ini akan memberikan akses kepada pengguna untuk menggeser rasio prioritas kecocokan secara mandiri, baik untuk memprioritaskan kemiripan botol kemasan (visual) maupun kesamaan komposisi bahan (tekstual).
3. Pengoptimalan Kamus *Stopword* Klinis: Untuk mengatasi masalah tingginya tumpang tindih data (*overlap*) akibat keberadaan bahan pelarut kosmetik komersial yang terlalu umum, tahapan pra-pemrosesan data teks (*text preprocessing*) dapat dioptimalkan kembali. Penelitian selanjutnya disarankan untuk menyertakan kamus *stopword* yang sangat spesifik pada domain dermatologi klinis, sehingga proses ekstraksi fitur teks menjadi lebih tajam dan akurat.

REFERENSI

- [1] “Indonesia Cosmetic Market Size, Share & Forecast Report 2032.” Accessed: Apr. 05, 2026. [Online]. Available: <https://www.gmiresearch.com/report/indonesia-cosmetic-market/>
- [2] “E-commerce Outlook 2025: Warga RI Akan Buru Produk FMCG yang Mendukung Perawatan Kulit! - Kompas.” Accessed: Apr. 05, 2026. [Online]. Available: <https://kompas.co.id/article/e-commerce-outlook-2025/>
- [3] A. A. Jannatin, “Perancangan Ontologi Skincare Untuk Sistem Rekomendasi Berbasis Preferensi Pengguna,” 2025, Accessed: Apr. 06, 2026. [Online]. Available: <https://dspace.uui.ac.id/handle/123456789/59065>
- [4] Assyfa Rasida Hanum. Eko Sakti Pramukantoro. Dany Primanita Kartikasari, “Studi Perbandingan Kinerja TF-IDF dan IndoBERT untuk Rekomendasi Resep Berdasarkan Ketersediaan Bahan Makanan Berbasis Website,” *Jurnal Pengembangan Teknologi Informasi dan Ilmu Komputer e*, vol. Vol. 9, Oct. 2025, Accessed: Apr. 06, 2026. [Online]. Available: <https://j-ptiik.ub.ac.id/index.php/j-ptiik/article/view/15384/6874>
- [5] K. Sakti Santriantara *et al.*, “DETEKSI ACNE VULGARIS DAN JENIS KULIT PADA CITRA WAJAH BERBASIS YOLOV7 DAN RESNET50,” *Jurnal Teknologi informasi dan Ilmu Komputer*, vol. 1, no. 3, pp. 120–130, Sep. 2025, doi: 10.65258/JUTEKOM.V1.I3.17.
- [6] A. Sulami, V. Atina, and N. Nurmalitasari, “Penerapan Metode Content Based Filtering dalam Sistem Rekomendasi Pemilihan Produk Skincare,” *STRING (Satuan Tulisan Riset dan Inovasi Teknologi)*, vol. 9, no. 2, pp. 172–181, Dec. 2024, doi: 10.30998/STRING.V9I2.24066.
- [7] D. A. Nouvalina and K. Hati, “The Skin Care Product Recommendation System Based on Facial Skin Problems using the Content Based Filtering Method,” *Jurnal Teknik Informatika STMIK Antar Bangsa*, vol. 10, no. 2, pp. 60–67, Aug. 2024, doi: 10.51998/JTI.V10I2.586.

- [8] K. C. Dewi and P. I. Ciptayani, "PEMODELAN SISTEM REKOMENDASI CERDAS MENGGUNAKAN HYBRID DEEP LEARNING," *Jurnal Sistem Informasi dan Sains Teknologi*, vol. 4, no. 2, Aug. 2022, doi: 10.31326/SISTEK.V4I2.1157.
- [9] H. Jurnal and D. A. Agustina, "KLASIFIKASI CITRA JENIS KULIT WAJAH DENGAN ALGORITMA CONVOLUTIONAL NEURAL NETWORK (CNN) RESNET-50," *Jurnal Riset Sistem Informasi*, vol. 1, no. 3, pp. 01–07, Jul. 2024, doi: 10.69714/13SBBY24.
- [10] M. I. Anshori, R. A. Yaqin, M. Ali, Z. Sidiq, I. Wiseto, and P. Agung, "Klasifikasi Jenis Jerawat Secara Otomatis Dengan Convolutional Neural Network Menggunakan Arsitektur Resnet-50," *Jurnal Manajemen Informatika (JAMIKA)*, vol. 15, no. 1, pp. 73–84, Apr. 2025, doi: 10.34010/JAMIKA.V15I1.13712.
- [11] V. S. Saputra, A. Ridwan, and T. G. Pratama, "RANCANG BANGUN SISTEM REKOMENDASI BUKU BERBASIS ITEM-BASED COLLABORATIVE FILTERING MENGGUNAKAN ALGORITMA K-NEAREST NEIGHBORS," *Jurnal Informatika dan Teknik Elektro Terapan*, vol. 13, no. 1, pp. 2830–7062, Jan. 2025, doi: 10.23960/JITET.V13I1.5995.
- [12] Putri Mariani Widia, Muchayan Achmad, and Kamisutara Made, "Sistem Rekomendasi Produk Pena Eksklusif Menggunakan Metode Content-Based Filtering dan TF-IDF," vol. 3, no. 1, pp. 229–236, 2018.
- [13] F. D. Astuti and W. Andriyani, "Pengembangan Sistem Rekomendasi Pembimbing Tugas Akhir Menggunakan Teknik Content Based Filtering," *JIKO (Jurnal Informatika dan Komputer)*, vol. 9, no. 2, pp. 474–483, Jun. 2025, doi: 10.26798/JIKO.V9I2.1599.
- [14] A. PADILA, "IMPLEMENTASI METODE HYBRID FILTERING (COLLABORATIVE FILTERING DAN CONTENT-BASED FILTERING) DALAM MEMBERIKAN REKOMENDASI KOST," Nov. 2023.

- [15] K. Dian, “PENDEKATAN BARU EKSTRAKSI INFORMASI BIOMEDICAL BIG DATA REPORT DENGAN BIOWORDVEC MENGGUNAKAN MODEL HYBRID LONG SHORT-TERM MEMORY – CONVOLUTIONAL NEURAL NETWORK (LSTM – CNN),” Mar. 2024.
- [16] T. Yuniarti, J. Astuti, F. Faujiyah, and M. Zaiyar, “Pendekatan Text Mining dalam Menilai Sentimen Publik pada Baterai Kendaraan Listrik,” vol. IX, no. 4, 2024.
- [17] “Teknik Cosine Similarity Dan TF-IDF Dalam Analisis Data - Randi Rian Putra, Nadya Andhika Putri, Agil Dwi Putra - Google Buku.” Accessed: Apr. 17, 2026.
- [18] G. H. Setiawan, I. Made, and B. Adnyana, “Improving Helpdesk Chatbot Performance with Term Frequency-Inverse Document Frequency (TF-IDF) and Cosine Similarity Models,” 2023. [Online]. Available: <http://jurnal.polibatam.ac.id/index.php/JAIC>
- [19] “Tutorial Object Detection People With Faster region-Based Convolutional.” Accessed: Apr. 17, 2026.
- [20] A. Arif Budiman, L. Nur Afifa, T. Setiyaningsih, and T. Amin Ridho, “Membangun Model Pengidentifikasi Kesegaran Daging dengan Metode Jaringan Syaraf Konvolusi (CNN) Jenis Resnet-50,” vol. 7, p. 113, 2023, doi: 10.37817/ikraith-informatika.v7i3.
- [21] R. Muzhaffar, I. Suharjo, T. Informasi, and U. Mercu Buana Yogyakarta, “Penerapan CNN Berbasis Arsitektur ResNet-50 untuk Klasifikasi Citra Beras Organik dan Anorganik,” *Jurnal Pustaka Data (Pusat Akses Kajian Database, Analisa Teknologi, dan Arsitektur Komputer)*, vol. 5, no. 2, pp. 351–358, Dec. 2025, doi: 10.55382/JURNALPUSTAKADATA.V5I2.1117.
- [22] M. Rizki, S. Saragih, and F. A. Siregar, “APLIKASI DETEKSI GAMBAR HASIL SCAN MENGGUNAKAN METODE COSINE SIMILARITY BERBASIS MOBILE,” *JATI (Jurnal Mahasiswa Teknik Informatika)*, vol. 8, no. 6, pp. 11598–11604, Nov. 2024, doi: 10.36040/JATI.V8I6.11546.

- [23] A. K. E. Pily, Susanti, U. Rio, and Tashid, "Komparasi K-Means Clustering dengan Euclidean dan Cosine Similarity untuk Segmentasi dan Rekomendasi Produk pada Data E-Commerce," *The Indonesian Journal of Computer Science*, vol. 14, no. 2, Apr. 2025, doi: 10.33022/IJCS.V14I2.4713.
- [24] S. Abimanyu, N. Bahtiar, and E. A. Sarwoko, "Implementasi Metode Support Vector Machine (SVM) dan t-Distributed Stochastic Neighbor Embedding (t-SNE) untuk Klasifikasi Depresi," *Jurnal Masyarakat Informatika*, vol. 14, no. 2, pp. 146–158, Nov. 2023, doi: 10.14710/JMASIF.14.2.59513.
- [25] A. Salam, M. Wali, dan F. P. Albahri, "Peningkatan Akurasi Rekomendasi Tugas Akhir Melalui Pendekatan Collaborative Filtering (CF) dan Content-Based Filtering (CBF)," *Jurnal Jambo Digitech*, vol. 1, no. 1, pp. 18-32, Jun. 2024.
- [26] F. Fitriyeh, N. Haqqi, L. M. Choiriyah, dan N. Ifada, "Dampak pembobotan pada metode hybrid user-based dan item-based untuk sistem rekomendasi film," *Jurnal Computer Science and Information Technology (CoSciTech)*, vol. 5, no. 3, pp. 516-525, Des. 2024.
- [27] D. Ariyus, D. Manongga, dan I. Sembiring, *Pengantar Sistem Rekomendasi: Teori dan Implementasi*. Purbalingga, Indonesia: CV. Eureka Media Aksara, 2024.
- [28] M. Z. F. Johari dan A. D. Laksito, "The Hybrid Recommender System of the Indonesian Online Market Products using IMDb weight rating and TF-IDF," *JURNAL RESTI (Rekayasa Sistem dan Teknologi Informasi)*, vol. 5, no. 5, pp. 977-983, Okt. 2021.
- [29] IBM, "What Is Text Mining?," IBM. [Online]. Available: <https://www.ibm.com/topics/text-mining>. [Accessed: Jun. 04, 2026].
- [30] Torch Contributors, "resnet50 — Torchvision main documentation," PyTorch. [Online]. Available:

- <https://pytorch.org/vision/main/models/generated/torchvision.models.resnet50.html>. [Accessed: Jun. 04, 2026].
- [31] scikit-learn developers, "TSNE — scikit-learn 1.9.0 documentation," scikit-learn. [Online]. Available: <https://scikit-learn.org/stable/modules/generated/sklearn.manifold.TSNE.html>. [Accessed: Jun. 04, 2026].
- [32] scikit-learn developers, "2.3. Clustering — scikit-learn 1.9.0 documentation," scikit-learn. [Online]. Available: <https://scikit-learn.org/stable/modules/clustering.html>. [Accessed: Jun. 04, 2026].
- [33] scikit-learn developers, "TfidfVectorizer — scikit-learn 1.9.0 documentation," scikit-learn. [Online]. Available: https://scikit-learn.org/stable/modules/generated/sklearn.feature_extraction.text.TfidfVectorizer.html. [Accessed: Jun. 04, 2026].
- [34] scikit-learn developers, "TfidfTransformer — scikit-learn 1.9.0 documentation," scikit-learn. [Online]. Available: https://scikit-learn.org/stable/modules/generated/sklearn.feature_extraction.text.TfidfTransformer.html. [Accessed: Jun. 04, 2026].
- [35] scikit-learn developers, "sklearn.metrics.pairwise.cosine_similarity — scikit-learn 1.9.0 documentation," scikit-learn. [Online]. Available: https://scikit-learn.org/stable/modules/generated/sklearn.metrics.pairwise.cosine_similarity.html. [Accessed: Jun. 04, 2026].
- [36] CS231n Contributors, "Convolutional Neural Networks (CNNs / ConvNets)," CS231n Deep Learning for Computer Vision. [Online]. Available: <https://cs231n.github.io/convolutional-networks/>. [Accessed: Jun. 04, 2026].